



EÖTVÖS LORÁND TUDOMÁNYEGYETEM

INFORMATIKAI KAR

INFORMÁCIÓS RENDSZEREK TANSZÉK

Fotográfiai témafelismerés neurális hálózatokkal nagy adathalmazon.

Témavezető:

Dr. Kiss Attila Elemér

Habilitált docens tanszékvezető

Szerző:

Sándor Balázs

Programtervező informatikus MSc

Budapest, 2025

DIPLOMAMUNKA TÉMABEJELENTŐ

Hallgató adatai:

Név: Sándor Balázs

Neptun kód: AZA6NL

Képzési adatok:

Szak: programtervező informatikus, mesterképzés (MA/MSc)

Tagozat : Nappali

Belső témavezetővel rendelkezem

Témavezető neve: Dr. Kiss Attila Elemér

munkahelyének neve, tanszéke: ELTE IK, Információs rendszerek Tanszék

munkahelyének címe: 1117, Budapest, Pázmány Péter sétány 1/C.

beosztás és iskolai végzettsége: beosztás: habilitált docens tanszékvezető, végzettség: matematikus

A diplomamunka címe: Fotográfiai témafelismerés neurális hálózatokkal nagy adathalmazon.

A diplomamunka témája:

(A témavezetővel konzultálva adja meg 1/2 - 1 oldal terjedelemben diplomamunka témájának leírását)

Fotográfiai témafelismerés neurális hálózatokkal nagy adathalmazon.

A dolgozat témája, a fotográfiai témák neurális hálózatokkal történő felismerése.

Saját nagyméretű fotóadatbázisomból a neurális hálózatok tanításához szükséges címkézett, konvertált, átméretezett fotóadatbázist készítek és elkészítem ennek leíró statisztikáit, hogy összehasonlítható legyen más tanító adathalmazokkal.

Összegyűjtöm a témában született korábbi írásokban alkalmazott mérési módszereket és metrikákat melyek az összehasonlítás alapját képezik majd.

Osztályozási feladatként, szükséges a célosztályok meghatározása, melyet a korábbi írásokban alkalmazott osztályok és a lokális adathalmaz sajátosságainak összefűzésével készítek el.

A korábbi írások alapján összegyűjtöm a szabadon elérhető modelleket és témafelismerési eljárásokat majd ezeket alkalmazom a saját nagyméretű adatbázisomra és az említett metrikák alapján összehasonlítom őket, majd saját megoldást készítek a korábbiak felhasználásával és ezt a meghatározott mérőszámok szerint összevetem a meglévőkkel.

Az írás célja a megismert módszerek közül a meghatározott metrikák szerinti legjobb megoldás meghatározása, ezek kombinálása, fejlesztése és az új megoldás eredményeinek összevetése a korábbiakkal. Vizsgálat tárgya még a nagy adathalmaz hatásainak vizsgálata a meglévő modellek minőségére és performanciájára.

Budapest, 2024. 05. 22.

Tartalomjegyzék

1. Absztrakt	4
2. Bevezető	5
2.1. Motiváció	6
2.2. Elérhetőség	7
2.2.1. Adatok elérhetősége	7
2.2.2. Finomhangolt modellek elérhetősége	7
2.2.3. Programkódok elérhetősége	7
2.3. Mellékletek	7
2.3.1. Melléklet A: Mérési napló	7
2.3.2. Melléklet B: Szoftverek	7
2.4. A feladat	7
2.4.1. Képosztályozás mint feladat	7
2.4.2. A konvolúciós neurális hálózatok mint megoldás	7
2.4.3. Képadatbázisok mint tanító eszközök	7
2.5. Irodalomkutatás	7
2.5.1. A metrikák	7
2.5.2. Áttekintő írások	8
2.5.3. A modellek és adathalmazok cikkei	8
2.5.4. Optimalizációs módszerek	8
2.5.5. Egyéb irodalom	9
3. Saját képadatbázis építése	10
3.1. A forrásképek	11
3.1.1. Motiváció	11
3.1.2. Források	11
3.2. Forrás adathalmaz elemzése	11
3.2.1. Darabszámok	11

3.2.2.	Méretek	11
3.2.3.	Kategóriák	11
3.3.	Adatbázis szerkezete	11
3.3.1.	Képméret, formátum	11
3.3.2.	Mappaszerkezet	11
3.3.3.	Kategóriák	11
3.3.4.	Osztályozás	11
3.4.	Előfeldolgozás	11
3.4.1.	Kötegelt adatgyűjtés	11
3.4.2.	Méret és teljesítmény korlátok	11
3.5.	Saját feldolgozó futószalag	11
3.5.1.	Tulajdonságok	11
3.5.2.	Szkript futószalag	11
3.5.3.	Performancia	11
3.5.4.	Automata osztályozás	11
3.5.5.	Places365	11
3.5.6.	ImageNet1K	11
3.5.7.	Kézi osztályozás	11
3.5.8.	Véglegesítés	11
3.6.	Utőfeldolgozás	11
3.6.1.	Kézi Adattisztítás, szűrés, törlés	11
3.6.2.	almappák elminiálása, nem lesznek alkategóriák	11
3.6.3.	kicsik eliminálása	11
3.6.4.	rendezés finomítása	11
3.6.5.	nagyok osztása	11
3.6.6.	arcfelismerés	11
3.6.7.	üres kategóriák törlése	11
3.6.8.	300 alatti kategóriák megszüntetése	11
3.7.	Kész adatbázis elemzése	11
3.8.	Statisztikák	11
3.8.1.	Darabszámok, méretek	11
3.8.2.	Mappavizsgáló szkript	11
3.8.3.	Kategóriák, statisztikák, méretek	11
3.8.4.	EXIF Statisztika szkript	11

3.8.5. EXIF statisztika	11
3.9. Az elkészült adatbázis értékelése	11
4. Összefoglaló	12
5. Befejezés	14
5.0.1. További lehetőségek	14
Irodalomjegyzék	14
Ábrajegyzék	18
Táblázatjegyzék	19
Forráskódjegyzék	20

1. fejezet

Absztrakt

A dolgozat célja egy nagyméretű, saját készítésű képadatbázis létrehozása és ezen mély neurális hálózatok osztályozási teljesítményének vizsgálata volt. Az SBphotothemes180k nevű adatbázis 180 750 egyedi, címkézett fényképet tartalmaz, kétféle annotációval: az ImageNet1K-ből szűrt 114, valamint a Places365-ből származó 121 kategóriával. Az osztályeloszlás erősen torzított, természetes adatok esetén tipikus, Long-tail eloszlást mutatott (aszimmetria: 8,4; szórás: 3200), de a nagy adatmennyiség és a szortírozási metodika révén kellően nagyra adódott az átlagos kategóriaméret is (1500). Az adatokon háromfázisú tesztelést végeztem hét népszerű, de különböző felépítésű neurális hálózaton (pl. ResNet50, EfficientNet-B0, ViT-B/16), különböző tanítóhalmaz-méretekkel. Az első lépés a tanítás nélküli modellek tesztelése volt a beépített súlyokkal, ezt követte a teljes tanítás, majd végül az iteratíván növekvő tanítóhalmazokon történő tesztelés. A modellek közül összességében az EfficientNet-B0 és a ConvNeXt-Tiny emelkedtek ki. A teljes adathalmazon tanított modellek közül az EfficientNet-B0 és a NASNet mutatták a legjobb teljesítményt (Top-1 pontosság 76%, Top-5 94%). Az utolsó fázisban a fokozatosan növelt tanítóhalmazokon mért teljesítményt vizsgáltam, hogy látható legyen a tanítóhalmaz méretének hatása. Ezen túl saját, erőforrástakarékos osztályozó modellt is fejlesztettem ResNet18-alapon, különféle fejrészekkel. Az egyszerű egyrétegű modell hasonló pontosságot ért el, mint az új modern fejrész, de az új modell számítási igénye jóval kisebb és pontossága összemérhető a nagy modellekével, így mobil eszközökön való alkalmazásra is alkalmas lehet. A nagyméretű adathalmaz, a többféle osztályozás, a nagy mennyiségű mért adat és a saját modellek további vizsgálatok alapját képezhetik a jövőben.

2. fejezet

Bevezető

Az utóbbi évtizedben a mesterséges intelligencia, különösen a mélytanulás (deep learning) területén tapasztalt fejlődés alapvetően átalakította a képfeldolgozás és számítógépes látás alkalmazásait. Az olyan modellek, mint a konvolúciós neurális hálózatok (CNN-ek), lehetővé tették a képek automatikus felismerését, osztályozását és tartalom szerinti csoportosítását, gyakran emberi szintű pontossággal. Az ilyen rendszerek sikere azonban nagymértékben függ a rendelkezésre álló nagy mennyiségű, jól címkézett adathalmazoktól. A legtöbb kutatás és alkalmazás olyan nyilvános benchmark adatkészleteken történik, mint az ImageNet vagy a Places365, amelyek széles körűek, de nem feltétlenül tükrözik a valós életből származó, természetes adatgyűjtés során keletkezett képek sokféleségét és osztályeloszlását. Jelen dolgozat célja egy valós, nem mesterségesen összeállított fotóadatbázison végzett osztályozási vizsgálat bemutatása. A saját készítésű, 20 év alatt összegyűlt fotógyűjteményből kiindulva egy nagyméretű (180 750 képből álló), kétféleképpen címkézett adatbázist hoztam létre, amely különlegessége, hogy minden képe egyedi, saját készítésű valós fotó, így ideális a természetes körülmények vizsgálatára. Az így előállított SBphotothemes180k adatbázison különböző népszerű neurális hálózatok (pl. ResNet, EfficientNet, Vision Transformer) osztályozási teljesítményét vizsgáltam többféle tanítási scenárióban, több metrika mentén. A dolgozat célja nem csupán a modellek pontosságának összehasonlítása, hanem annak feltárása is, hogy milyen mértékben képesek a különböző architektúrák megbirkózni a nem kiegyensúlyozott osztályeloszlással és a természetes körülmények között gyűjtött adatok sokféleségével és a különféle tanítóhalmaz méreteivel. Emellett saját erőforrás-takarékos modell fejlesztésével is kísérletet tettem olyan alkalmazások számára, ahol a számítási teljesítmény

korlátozott - például mobil vagy beágyazott rendszerek esetében.

2.1. Motiváció

A fényképezés számomra több mint hobbi: általános iskolás korom óta szerves része az életemnek. A fénykép egyrészt az emlékek megbízható őrzője, másrészt az önkifejezés egyedi formája is. Úgy gondolom, hogy egy jól elkészített fotó gyakran többet árul el az alkotóról, mint magáról a témáról. 2008 óta intenzíven foglalkozom fotózással, majd 2010-ben a Kalocsai Szent István Gimnázium stúdiójában, - amit Lakatos Ervin festőművész vezetett - mélyültem el a fényképezés művészi és tudatos megközelítésében. Ekkor kezdtem el a fotózást nem pusztán dokumentációs eszközként, hanem alkotói folyamatként gyakorolni. Azóta is aktívan fotózom, gyűjtöm, rendszerezem és archiválom a képeimet. A fotóim gyakran szorosan összekapcsolódnak más hobbijaimmal is: természetjárás, repülés, zene, csillagászat, valamint az állat- és növényvilág iránti érdeklődésem mind nyomot hagynak a képeimen. A vizualitás mindig is meghatározó szerepet játszott a gondolkodásomban. Programtervező informatikus alapszakos tanulmányaim során például háromdimenziós szimulációval foglalkoztam a szakdolgozatomban. A mesterképzésen - az információs rendszerek szakirányon - mélyebb betekintést nyerhettem a mesterséges intelligencia, azon belül is a mély neurális hálózatok működésébe és alkalmazási lehetőségeibe. A képzés során hamar szembesültem azzal, hogy a gépi tanulási rendszerek fejlesztésének egyik legnagyobb akadálya a minőségi, kellően címkézett adathalmazok hiánya. Ekkor tudatosult bennem, hogy az elmúlt évtizedek során saját magam által készített és gondosan karbantartott fotótár egyedülálló lehetőséget kínál egy valós, természetes környezetből származó adathalmaz kialakítására. Ez a felismerés adta a jelen diplomamunka ötletét: saját fotógyűjteményemet felhasználva egy neurális hálózatokkal végzett képosztályozási vizsgálatot hajtottam végre, amely egyszerre kapcsolódik szakmai érdeklődésemhez és személyes szenvedélyemhez is.

2.2. Elérhetőség

2.2.1. Adatok elérhetősége

2.2.2. Finomhangolt modellek elérhetősége

2.2.3. Programkódok elérhetősége

2.3. Mellékletek

2.3.1. Melléklet A: Mérési napló

2.3.2. Melléklet B: Szoftverek

2.4. A feladat

2.4.1. Képosztályozás mint feladat

2.4.2. A konvolúciós neurális hálózatok mint megoldás

2.4.3. Képadatbázisok mint tanító eszközök

2.5. Irodalomkutatás

A diplomamunka elkészítése során elsősorban a képzés során végzett Bevezetés a gépi tanulásba, Gépi tanulás alapjai Python-ban és Deep Learning kurzusokon tanultakra támaszkodtam, de a munka kezdete előtt olvastam a felhasznált modelleket bemutató cikkeket, survey cikkeket és a témába vágó egyéb írásokat. Ebben a részben ezeket szeretném bemutatni. (A felhasznált irodalmak listája a projekt GitHub könyvtárában is megtalálható.)

2.5.1. A metrikák

Az alkalmazott metrikák megértésében és kiválasztásában nagy segítségemre volt az "Image Classification with Convolutional Neural Networks"[1] című írás.

2.5.2. Áttekintő írások

Az irodalomkutatást áttekintő művek keresésével és értelmezésével kezdtem.

- "A Survey of Convolutional Neural Networks: Analysis, Applications, and Prospects"[2]
- "Review of deep learning: concepts, CNN architectures, challenges, applications, future directions"[3]
- "Understanding Deep Convolutional Networks"[4]
- "Benchmarking Neural Network Training Algorithms"[5]

2.5.3. A modellek és adathalmazok cikkei

Természetesen nagyon nagy segítséget jelentettek a felhasznált modelleket és kategorizálásokat ismertető írások. Ezek az írások a következők:

- A ResNet50 modell ismertetése.[6]
- DenseNet121 modell ismertetése.[7]
- EfficientNet-B0 modell ismertetése.[8]
- ConvNeXt-Tiny modell ismertetése.[9]
- ViT-B/16 modell ismertetése.[10]
- Inception-v3 modell ismertetése.[11]
- NASNet modell ismertetése.[12]
- ImageNet1K osztályozás ismertetése.[13]
- Places365 osztályozás ismertetése.[14]

2.5.4. Optimalizációs módszerek

Amikor az új modellt terveztem több optimalizációs megoldásnak is utánanéztem. Az alábbiakban az ezekhez tartozó irodalmakat sorolom fel.

- GELU (Gaussian Error Linear Unit) aktivációs függvény[15]

- Layer Normalization[16]
- Dropout regulárizáció[17]
- Batch Normalization (BatchNorm)[18]
- Adaptive Average Pooling (AdaptiveAvgPool2d)[19]

2.5.5. Egyéb irodalom

A további cikkek és írások amiket áttekintettem a munka megkezdése előtt az alábbiak:

- "A Survey on Deep Transfer Learning and Beyond"[20]
- "Landscape photo classification mechanism for context-aware photography support system" [21]
- "Photo Content Classification Using Convolutional Neural Network" [22]
- "An Analysis Of Convolutional Neural Networks For Image Classification"[23]

3. fejezet

Saját képadatbázis építése

3.1. A forrásképek

3.1.1. Motiváció

3.1.2. Források

3.2. Forrás adathalmaz elemzése

3.2.1. Darabszámok

3.2.2. Méretek

3.2.3. Kategóriák

3.3. Adatbázis szerkezete

3.3.1. Képméret, formátum

3.3.2. Mappaszerkezet

3.3.3. Kategóriák

3.3.4. Osztályozás

3.4. Előfeldolgozás

3.4.1. Kötegelt adatgyűjtés

3.4.2. Méret és teljesítmény korlátok

3.5. Saját feldolgozó futószalag

3.5.1. Tulajdonságok

3.5.2. Szkript futószalag

Konvertálás

Méretezés

4. fejezet

Összefoglaló

A dolgozat célja a fotó osztályozási probléma vizsgálata volt neurális hálózatokkal saját nagyméretű címkézett adatbázison. A vizsgálat során összegyűjtöttem 180750 egyedi fotót az elmúlt 20 év saját készítésű képeiből, ebből címkézett adatbázist készítettem SBphotothemes180k néven kétféle címkézéssel. Az ImageNet1K címkékből 114 kategória adta az első osztályozást a 300 képnél kisebb osztályok megszüntetése után, a Places365 címkékből 121 kategória adta a második osztályozást. Ezek után 80-10-10 arányban felosztottam tanító, validáló és tesztelő adathalmazra az adatbázist. Az adathalmaz képeit 224*244 méretű négyzetes jpg 80 tömörítésű képekké konvertáltam. Így a közel 2TB mennyiségű forrásképből nagyjából 10GB méretű adatbázis készült. Az elkészült adatbázison vizsgáltam az osztályozási eloszlásokat, és az EXIF adatokat. Az osztályozások estén az átlagos osztályméret 1500 kép körül alakult, a medián 1000 kép körül alakult ami jó, de mivel természetes adatokról beszélünk, így az aszimmetria magas, 8.4 és a szórás is magas 3200 körüli tehát tipikus Long-tail eloszlást mutat. Az EXIF adatok konverzió közbeni megőrzése és elemzése különösen fontos volt a részletes statisztikák elvégzéséhez és a későbbi vizsgálatok lehetőségeinek biztosításához. Az így elkészített adatbázis segítségével három fázisos vizsgálatot végeztem hét ismert és gyakran használt modellen. Ezek a modellek a ResNet50, DenseNet121, EfficientNet-B0, ConvNeXt-Tiny, ViT-B/16, Inception-v3, NASNet voltak. Az alkalmazott metrikák a következők lettek: Top-1 és Top-5 pontosság, Precision, Recall, F1-score. Ezeken túl vizsgáltam a tanítás közbeni validációs és tanítási pontosságokat. Mindhárom vizsgálatot ugyanazon az adathalmazon végeztem, de más-más tanítóhalmazzal tanítottam. A három vizsgálati fázis a tanítás nélküli tesztelés, majd a teljes tanítás utáni vizsgálat volt, végül az iteratívan

növekvő tanítóhalmaz vizsgálata következett. A vizsgálat első lépése a tanítás nélküli modellek tesztelése volt a beépített súlyokkal. Ekkor a modellek 50% körüli Top 1 és 80% körüli Top 5 pontosságot és 40% körüli Precision-t nyújtottak. Itt a ConvNeXt-Tiny és ViT-B/16 emelkedtek ki. A második fázis során a teljes 144000 képes tanítóhalmazon tanítottam minden modellt 10 epoch-on keresztül. Ekkor a modellek 75% körüli Top 1 és 90% körüli Top 5 pontosságot és 70% körüli Precision-t nyújtottak a EfficientNet-B0 és NASNet emelkedtek ki. Az utolsó vizsgálat során mindig a tanítatlan modelltől indulva 1000, 5000, 10000, 25000 képes tanítóhalmazon vizsgáltam a modelleket szintén 10 epoch-on keresztül. Az adataink alapján a ConvNeXt-Tiny és az EfficientNet-B0 modellek kiemelkedtek 25000 mintaszámmal történő tanítás után, míg a ResNet50 és DenseNet121 modellek gyengébben teljesítettek az alacsonyabb mintaszámokon, de növekvő mintaszámmal jelentős javulást mutattak. Eközben az Inception-v3 és a ViT-B/16 pedig a kis adathalmazon mutatott pontosság terén emelkedtek ki. Ezután megkíséreltem elkészíteni egy kis méretű, lokális alkalmazásra optimalizált erőforrástakarékos modellt a ResNet18-ra építve egy saját fejrész kifejlesztésével. Ennek során 4 modellt készítettem, egy egyrétegű, egy mély, és két modern fejrésszel rendelkezőt. Ezen a négy modellen is elvégeztem a fent ismertetett három mérési fázist. Az egyrétegű fej meglepően jól teljesített, a mély fejrész viszont jelentősen alulmaradt a fenti metrikákban, a modern fejrész csak kicsit nyújtott nagyobb pontosságot, mint az egyrétegű, de jelentősen gyorsabban futott. Összességében a kifejlesztett modell csak kis mértékben maradt alul a vizsgált hatalmas modellektől, de futási teljesítménye sokkal jobb azokénál így nem pontosságkritikus, de erőforráskímélő megoldásokhoz, például hordozható eszközök számára ideális. Összességében a nagyméretű adathalmaz, a többféle osztályozás, a nagy mennyiségű mért adat és a saját modellek további vizsgálatok alapját képezhetik a jövőben.

5. fejezet

Befejezés

5.0.1. További lehetőségek

Irodalomjegyzék

- [1] Alfonso Ramos Michel és tsai. *Image Classification with Convolutional Neural Networks*. 2021. júl., 445–473. old. ISBN: 978-3-030-70541-1. DOI: 10.1007/978-3-030-70542-8_18.
- [2] Zewen Li és tsai. „A Survey of Convolutional Neural Networks: Analysis, Applications, and Prospects”. *arXiv preprint arXiv:2004.02806* (2020).
- [3] Laith Alzubaidi és tsai. „Review of deep learning: concepts, CNN architectures, challenges, applications, future directions”. *Journal of Big Data* 8.1 (2021), 53. old.
- [4] Stéphane Mallat. „Understanding Deep Convolutional Networks”. *arXiv preprint arXiv:1601.04920* (2016).
- [5] MLCommons Algorithms Working Group. *Benchmarking Neural Network Training Algorithms*. <https://arxiv.org/html/2306.07179>. 2023.
- [6] Kaiming He és tsai. „Deep Residual Learning for Image Recognition”. *arXiv preprint arXiv:1512.03385* (2015).
- [7] Gao Huang és tsai. „Densely Connected Convolutional Networks”. *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2017, 4700–4708. old.
- [8] Mingxing Tan és Quoc V Le. „EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks”. *International Conference on Machine Learning*. PMLR. 2019, 6105–6114. old.
- [9] Zhuang Liu és tsai. „A ConvNet for the 2020s”. *arXiv preprint arXiv:2201.03545* (2022).
- [10] Alexey Dosovitskiy és tsai. „An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale”. *arXiv preprint arXiv:2010.11929* (2020).

- [11] Christian Szegedy és tsai. „Rethinking the Inception Architecture for Computer Vision”. *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2016, 2818–2826. old.
- [12] Barret Zoph és tsai. „Learning Transferable Architectures for Scalable Image Recognition”. *arXiv preprint arXiv:1707.07012* (2017).
- [13] Jia Deng és tsai. „ImageNet: A Large-Scale Hierarchical Image Database”. *2009 IEEE Conference on Computer Vision and Pattern Recognition*. IEEE. 2009, 248–255. old.
- [14] Bolei Zhou és tsai. „Places: A 10 million Image Database for Scene Recognition”. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. 2017, 1452–1460. old.
- [15] Dan Hendrycks és Kevin Gimpel. „Gaussian Error Linear Units (GELUs)”. *arXiv preprint arXiv:1606.08415* (2016).
- [16] Jimmy Lei Ba, Jamie Ryan Kiros és Geoffrey E Hinton. „Layer Normalization”. *arXiv preprint arXiv:1607.06450* (2016).
- [17] Nitish Srivastava és tsai. „Dropout: A Simple Way to Prevent Neural Networks from Overfitting”. *Journal of Machine Learning Research*. 15. köt. 2014, 1929–1958. old.
- [18] Sergey Ioffe és Christian Szegedy. „Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift”. *Proceedings of the 32nd International Conference on Machine Learning*. 2015, 448–456. old.
- [19] Kaiming He és tsai. „Spatial Pyramid Pooling in Deep Convolutional Networks for Visual Recognition”. *European Conference on Computer Vision*. 2014, 346–361. old.
- [20] Y. Zhang, S. Wang és Y. Liu. „A Survey on Deep Transfer Learning and Beyond”. *Mathematics* 10.19 (2022), 3619. old.
- [21] Nuttapoom Amornpashara és tsai. „Landscape photo classification mechanism for context-aware photography support system”. *2015 IEEE International Conference on Consumer Electronics (ICCE)*. 2015, 663–666. old. DOI: 10.1109/ICCE.2015.7066570.

- [22] Yilin Hou. „Photo Content Classification Using Convolutional Neural Network”. *Journal of Physics: Conference Series* 1651.1 (2020. nov.), 12179. old. DOI: 10.1088/1742-6596/1651/1/012179. URL: <https://dx.doi.org/10.1088/1742-6596/1651/1/012179>.
- [23] Neha Sharma, Vibhor Jain és Anju Mishra. „An Analysis Of Convolutional Neural Networks For Image Classification”. *Procedia Computer Science* 132 (2018. jan.), 377–384. old. DOI: 10.1016/j.procs.2018.05.198.

Ábrák jegyzéke

Táblázatok jegyzéke

Forráskódjegyzék