



EÖTVÖS LORÁND TUDOMÁNYEGYETEM

INFORMATIKAI KAR

INFORMÁCIÓS RENDSZEREK TANSZÉK

Fotográfiai témafelismerés neurális hálózatokkal nagy adathalmazon.

Témavezető:

Dr. Kiss Attila Elemér

Habilitált docens tanszékvezető

Szerző:

Sándor Balázs

Programtervező informatikus MSc

Budapest, 2025

DIPLOMAMUNKA TÉMABEJELENTŐ

Hallgató adatai:

Név: Sándor Balázs

Neptun kód: AZA6NL

Képzési adatok:

Szak: programtervező informatikus, mesterképzés (MA/MSc)

Tagozat : Nappali

Belső témavezetővel rendelkezem

Témavezető neve: Dr. Kiss Attila Elemér

munkahelyének neve, tanszéke: ELTE IK, Információs rendszerek Tanszék

munkahelyének címe: 1117, Budapest, Pázmány Péter sétány 1/C.

beosztás és iskolai végzettsége: beosztás: habilitált docens tanszékvezető, végzettség: matematikus

A diplomamunka címe: Fotográfiai témafelismerés neurális hálózatokkal nagy adathalmazon.

A diplomamunka témája:

(A témavezetővel konzultálva adja meg 1/2 - 1 oldal terjedelemben diplomamunka témájának leírását)

Fotográfiai témafelismerés neurális hálózatokkal nagy adathalmazon.

A dolgozat témája, a fotográfiai témák neurális hálózatokkal történő felismerése.

Saját nagyméretű fotóadatbázisomból a neurális hálózatok tanításához szükséges címkézett, konvertált, átméretezett fotóadatbázist készítek és elkészítem ennek leíró statisztikáit, hogy összehasonlítható legyen más tanító adathalmazokkal.

Összegyűjtöm a témában született korábbi írásokban alkalmazott mérési módszereket és metrikákat melyek az összehasonlítás alapját képezik majd.

Osztályozási feladatként, szükséges a célosztályok meghatározása, melyet a korábbi írásokban alkalmazott osztályok és a lokális adathalmaz sajátosságainak összefűzésével készítek el.

A korábbi írások alapján összegyűjtöm a szabadon elérhető modelleket és témafelismerési eljárásokat majd ezeket alkalmazom a saját nagyméretű adatbázisomra és az említett metrikák alapján összehasonlítom őket, majd saját megoldást készítek a korábbiak felhasználásával és ezt a meghatározott mérőszámok szerint összevetem a meglévőkkel.

Az írás célja a megismert módszerek közül a meghatározott metrikák szerinti legjobb megoldás meghatározása, ezek kombinálása, fejlesztése és az új megoldás eredményeinek összevetése a korábbiakkal. Vizsgálat tárgya még a nagy adathalmaz hatásainak vizsgálata a meglévő modellek minőségére és performanciájára.

Budapest, 2024. 05. 22.

Tartalomjegyzék

1. Absztrakt	6
2. Bevezető	7
2.1. Motiváció	8
2.2. Elérhetőség	8
2.2.1. Adatok elérhetősége	9
2.2.2. Finomhangolt modellek elérhetősége	9
2.2.3. Programkódok elérhetősége	10
2.3. Mellékletek	10
2.3.1. Melléklet A: Mérési napló	11
2.3.2. Melléklet B: Szoftverek	11
2.4. A feladat	12
2.4.1. Képosztályozás mint feladat	13
2.4.2. A konvolúciós neurális hálózatok mint megoldás	13
2.4.3. Képadatbázisok mint tanító eszközök	14
2.5. Irodalomkutatás	15
2.5.1. A metrikák	16
2.5.2. Áttekintő írások	16
2.5.3. A modellek és adathalmazok cikkei	16
2.5.4. Optimalizációs módszerek	17
2.5.5. Egyéb irodalom	17
3. Saját képadatbázis építése	18
3.1. A forrásképek	19
3.1.1. Motiváció	19
3.1.2. Források	19
3.2. Forrás adathalmaz elemzése	19
3.2.1. Darabszámok	19

3.2.2.	Méretetek	19
3.2.3.	Kategóriák	19
3.3.	Adatbázis szerkezete	19
3.3.1.	Képméret, formátum	19
3.3.2.	Mappaszerkezet	19
3.3.3.	Kategóriák	19
3.3.4.	Osztályozás	19
3.4.	Előfeldolgozás	19
3.4.1.	Kötegetelt adatgyűjtés	19
3.4.2.	Méret és teljesítmény korlátok	19
3.5.	Saját feldolgozó futószalag	19
3.5.1.	Tulajdonságok	19
3.5.2.	Szkript futószalag	19
3.5.3.	Performancia	19
3.5.4.	Automata osztályozás	19
3.5.5.	Places365	19
3.5.6.	ImageNet1K	19
3.5.7.	Kézi osztályozás	19
3.5.8.	Véglegesítés	19
3.6.	Utőfeldolgozás	19
3.6.1.	Kézi Adattisztítás, szűrés, törlés	19
3.6.2.	almappák elminiálása, nem lesznek alkategóriák	19
3.6.3.	kicsik eliminálása	19
3.6.4.	rendezés finomítása	19
3.6.5.	nagyok osztása	19
3.6.6.	arcfelismerés	19
3.6.7.	üres kategóriák törlése	19
3.6.8.	300 alatti kategóriák megszüntetése	19
3.7.	Kész adatbázis elemzése	19
3.8.	Statisztikák	19
3.8.1.	Darabszámok, méretek	19
3.8.2.	Mappavizsgáló szkript	19
3.8.3.	Kategóriák, statisztikák, méretek	19
3.8.4.	EXIF Statisztika szkript	19

3.8.5. EXIF statisztika	19
3.9. Az elkészült adatbázis értékelése	19
4. Modellek és metrikák kiválasztása	20
4.1. Metodika	21
4.2. Kiválasztott modellek	21
4.2.1. ResNet50	21
4.2.2. DenseNet121	21
4.2.3. EfficientNet-B0	21
4.2.4. ConvNeXt-Tiny	21
4.2.5. ViT-B/16	21
4.2.6. Inception-v3	21
4.2.7. NASNet	21
4.3. A kiválasztott metrikák:	21
4.3.1. Top-1 pontosság	21
4.3.2. Top-5 pontosság	21
4.3.3. Precision	21
4.3.4. Recall	21
4.3.5. F1-score	21
4.3.6. Train és Val loss	21
4.3.7. Train és Val pontosság	21
4.4. Összegzés	21
5. Vizsgálati metodika	22
5.1. I. Fázis: Tanítás nélküli tesztelés	22
5.2. II. Fázis: Teljes tanítás	22
5.3. III. Fázis: Iteratív tanítás	22
5.4. IV. Fázis: Saját modell fejlesztése	22
6. Szoftveres környezet	23
6.1. Lokális vagy Online	23
6.2. Google Colab lehetőségek	23
6.3. Tárolási problémák	23
6.4. Tanító és tesztelő programok	23
6.4.1. Tesztelés	23

6.4.2.	Tanítás	23
6.4.3.	Mérés	23
6.4.4.	Problémák és megoldások	23
6.5.	Összefoglalás	23
7.	I. Fázis: Tanítás nélküli tesztelés	24
7.1.	ResNet50	24
7.2.	DenseNet121	24
7.3.	EfficientNet-B0	24
7.4.	ConvNeXt-Tiny	24
7.5.	ViT-B/16	24
7.6.	Inception-v3	24
7.7.	NASNet	24
7.8.	Összefoglaló	24
8.	II. Fázis: Teljes tanítás	25
8.1.	ResNet50	25
8.2.	DenseNet121	25
8.3.	EfficientNet-B0	25
8.4.	ConvNeXt-Tiny	25
8.5.	ViT-B/16	25
8.6.	Inception-v3	25
8.7.	NASNet	25
8.8.	Összefoglaló	25
9.	III. Fázis: Iteratív tanítás	26
9.1.	ResNet50	26
9.2.	DenseNet121	26
9.3.	EfficientNet-B0	26
9.4.	ConvNeXt-Tiny	26
9.5.	ViT-B/16	26
9.6.	Inception-v3	26
9.7.	NASNet	26
9.8.	Összefoglaló	26

10.IV. Fázis: Saját modell fejlesztése	27
10.1. A ResNet18	27
10.2. A Base fej	27
10.3. A Deep fej	27
10.4. A Hybrid-v1 fej	27
10.5. A Hybrid-v2 fej	27
10.6. Mérések	27
10.6.1. I. Fázis: Tanítás nélküli tesztelés	27
10.6.2. II. Fázis: Teljes tanítás	27
10.6.3. III. Fázis: Iteratív tanítás	27
10.7. Összefoglalás	27
11. Legfontosabb eredmények	28
12. Összefoglaló	29
13. Befejezés	31
13.0.1. További lehetőségek	31
Irodalomjegyzék	32
Ábrajegyzék	35
Táblázatjegyzék	36
Forráskódjegyzék	37

1. fejezet

Absztrakt

A dolgozat célja egy nagyméretű, saját készítésű képadatbázis létrehozása és ezen mély neurális hálózatok osztályozási teljesítményének vizsgálata volt. Az SBphotothemes180k nevű adatbázis 180 750 egyedi, címkézett fényképet tartalmaz, kétféle annotációval: az ImageNet1K-ből szűrt 114, valamint a Places365-ből származó 121 kategóriával. Az osztályeloszlás erősen torzított, természetes adatok esetén tipikus, Long-tail eloszlást mutatott (aszimmetria: 8,4; szórás: 3200), de a nagy adatmennyiség és a szortírozási metodika révén kellően nagyra adódott az átlagos kategóriaméret is (1500). Az adatokon háromfázisú tesztelést végeztem hét népszerű, de különböző felépítésű neurális hálózaton (pl. ResNet50, EfficientNet-B0, ViT-B/16), különböző tanítóhalmaz-méretekkel. Az első lépés a tanítás nélküli modellek tesztelése volt a beépített súlyokkal, ezt követte a teljes tanítás, majd végül az iteratíván növekvő tanítóhalmazokon történő tesztelés. A modellek közül összességében az EfficientNet-B0 és a ConvNeXt-Tiny emelkedtek ki. A teljes adathalmazon tanított modellek közül az EfficientNet-B0 és a NASNet mutatták a legjobb teljesítményt (Top-1 pontosság 76%, Top-5 94%). Az utolsó fázisban a fokozatosan növelt tanítóhalmazokon mért teljesítményt vizsgáltam, hogy látható legyen a tanítóhalmaz méretének hatása. Ezen túl saját, erőforrástakarékos osztályozó modellt is fejlesztettem ResNet18-alapon, különféle fejrészekkel. Az egyszerű egyrétegű modell hasonló pontosságot ért el, mint az új modern fejrész, de az új modell számítási igénye jóval kisebb és pontossága összemérhető a nagy modellekével, így mobil eszközökön való alkalmazásra is alkalmas lehet. A nagyméretű adathalmaz, a többféle osztályozás, a nagy mennyiségű mért adat és a saját modellek további vizsgálatok alapját képezhetik a jövőben.

2. fejezet

Bevezető

Az utóbbi évtizedben a mesterséges intelligencia, különösen a mélytanulás (deep learning) területén tapasztalt fejlődés alapvetően átalakította a képfeldolgozás és számítógépes látás alkalmazásait. Az olyan modellek, mint a konvolúciós neurális hálózatok (CNN-ek), lehetővé tették a képek automatikus felismerését, osztályozását és tartalom szerinti csoportosítását, gyakran emberi szintű pontossággal. Az ilyen rendszerek sikere azonban nagymértékben függ a rendelkezésre álló nagy mennyiségű, jól címkézett adathalmazoktól. A legtöbb kutatás és alkalmazás olyan nyilvános benchmark adatkészleteken történik, mint az ImageNet vagy a Places365, amelyek széles körűek, de nem feltétlenül tükrözik a valós életből származó, természetes adatgyűjtés során keletkezett képek sokféleségét és osztályeloszlását. Jelen dolgozat célja egy valós, nem mesterségesen összeállított fotóadatbázison végzett osztályozási vizsgálat bemutatása. A saját készítésű, 20 év alatt összegyűlt fotógyűjteményből kiindulva egy nagyméretű (180 750 képből álló), kétféleképpen címkézett adatbázist hoztam létre, amely különlegessége, hogy minden képe egyedi, saját készítésű valós fotó, így ideális a természetes körülmények vizsgálatára. Az így előállított SBphotothemes180k adatbázison különböző népszerű neurális hálózatok (pl. ResNet, EfficientNet, Vision Transformer) osztályozási teljesítményét vizsgáltam többféle tanítási scenárióban, több metrika mentén. A dolgozat célja nem csupán a modellek pontosságának összehasonlítása, hanem annak feltárása is, hogy milyen mértékben képesek a különböző architektúrák megbirkózni a nem kiegyensúlyozott osztályeloszlással és a természetes körülmények között gyűjtött adatok sokféleségével és a különféle tanítóhalmaz méretekkel. Emellett saját erőforrás-takarékos modell fejlesztésével is kísérletet tettem olyan alkalmazások számára, ahol a számítási teljesítmény

korlátozott - például mobil vagy beágyazott rendszerek esetében.

2.1. Motiváció

A fényképezés számomra több mint hobbi: általános iskolás korom óta szerves része az életemnek. A fénykép egyrészt az emlékek megbízható őrzője, másrészt az önkifejezés egyedi formája is. Úgy gondolom, hogy egy jól elkészített fotó gyakran többet árul el az alkotóról, mint magáról a témáról. 2008 óta intenzíven foglalkozom fotózással, majd 2010-ben a Kalocsai Szent István Gimnázium stúdiójában, - amit Lakatos Ervin festőművész vezetett - mélyültem el a fényképezés művészi és tudatos megközelítésében. Ekkor kezdtem el a fotózást nem pusztán dokumentációs eszközként, hanem alkotói folyamatként gyakorolni. Azóta is aktívan fotózom, gyűjtöm, rendszerezem és archiválom a képeimet. A fotóim gyakran szorosan összekapcsolódnak más hobbijaimmal is: természetjárás, repülés, zene, csillagászat, valamint az állat- és növényvilág iránti érdeklődésem mind nyomot hagynak a képeimen. A vizualitás mindig is meghatározó szerepet játszott a gondolkodásomban. Programtervező informatikus alapszakos tanulmányaim során például háromdimenziós szimulációval foglalkoztam a szakdolgozatomban. A mesterképzésen - az információs rendszerek szakirányon - mélyebb betekintést nyerhettem a mesterséges intelligencia, azon belül is a mély neurális hálózatok működésébe és alkalmazási lehetőségeibe. A képzés során hamar szembesültem azzal, hogy a gépi tanulási rendszerek fejlesztésének egyik legnagyobb akadálya a minőségi, kellően címkézett adathalmazok hiánya. Ekkor tudatosult bennem, hogy az elmúlt évtizedek során saját magam által készített és gondosan karbantartott fotótár egyedülálló lehetőséget kínál egy valós, természetes környezetből származó adathalmaz kialakítására. Ez a felismerés adta a jelen diplomamunka ötletét: saját fotógyűjteményemet felhasználva egy neurális hálózatokkal végzett képosztályozási vizsgálatot hajtottam végre, amely egyszerre kapcsolódik szakmai érdeklődésemhez és személyes szenvedélyemhez is.

2.2. Elérhetőség

A munka során fontos volt számomra, hogy minden lépést gondosan dokumentáljak és az összes adatot, a finomhangolt modelleket és az adatbázis építéshez, valamint a tanításhoz és mérésekhez készített szoftvereket elérhetővé tegyem.

Mivel a projekt során igen nagy méretű fájlok keletkeztek - összesen 48,5GB -, így ezek az egyetemi OneDrive fiókom segítségével kerültek megosztásra.

A projekt OneDrive mappájának elérhetősége:

https://ikelte-my.sharepoint.com/:f:/g/personal/sabuaai_inf_elte_hu/ElwbJQikJ7VJqM1u5lmhhNMBq0_falCiRZTuLwoimmdrpA?e=hGFCxI

Az elkészült szoftverek a projekt GitHub könyvtárában találhatóak, ennek mérete nem olyan jelentős, de sok fájlt tartalmaz.

A projekt GitHub repository-ja:

<https://github.com/SandorBalazsHU/elte-ik-msc-thesis>

2.2.1. Adatok elérhetősége

Az elkészült adatbázis a projekt OneDrive mappájában találhatóak. A megosztott OneDrive mappa felépítése az alábbi:

- `fine_tuned_models.zip` - 1,14GB - Ebben találhatóak a feltanított modellek
- `sbphotothemes180k.zip` - 9,48GB - Ebben található a rendezetlen képhalmaz
- `sbphotothemes180k_imagenet114.zip` - 9,48GB - Ebben található az ImageNet1k alapján 114 osztályra szortírozott képhalmaz.
- `sbphotothemes180k_imagenet114_split_80_10_10.zip` - 9,48GB - Ebben található az ImageNet1k alapján 114 osztályra szortírozott képhalmaz 80-10-10 Train, Val, Test felosztása tanításra készen.
- `sbphotothemes180k_places121.zip` - 9,48GB - Ebben található a Places365 alapján 121 osztályra szortírozott képhalmaz.
- `sbphotothemes180k_places121_split_80_10_10.zip` - 9,48GB - Ebben található a Places365 alapján 121 osztályra szortírozott képhalmaz 80-10-10 Train, Val, Test felosztása tanításra készen.

2.2.2. Finomhangolt modellek elérhetősége

Minden modell amin teljes finomhangolást végeztem a teljes tanítóhalmazon mentésre került további vizsgálatokhoz. Ezek a OneDrive könyvtár alábbi mappájában érhetőek el:

- `fine_tuned_models.zip` - 1,14GB - Ebben találhatóak a feltanított modellek

Ebben a tömörített könyvtárban a fájlok nevei egyértelműen jelzik, hogy melyik fájl melyik finomhangolt modellt tartalmazza.

2.2.3. Programkódok elérhetősége

A projekthez készült számos Jupyter notebook, python és bash szkript rendezett formában a projekt GitHub könyvtárában érhető el. A könyvtár felépítése a következő:

- `literature` - Az összegyűjtött irodalmat tartalmazó mappa
- `notebooks` - A tanításhoz és vizsgálatokhoz használt GoogleColab notebook-ok. Ezek minden elvégzett lépést részletesen dokumentálnak. Nem csak a programkódot, hanem az eredményeket és a kommenteket is rendezett formában rögzítik. A négy vizsgálati fázishoz 1-1 mappa tartozik és az adatbázis építéshez egy külön `db` nevű mappa. Az eredmény összegző notebook-ok is itt találhatóak.
- `scripts` - Ebben a mappában találhatóak az elkészült egyéb segédprogramok. A `cnn` mappában a modellekhez és a vizsgálatokhoz kötődő elkészített szoftverek találhatóak, a `db` mappában pedig az adatbázis építéshez készített kódok szerepelnek.
- `thesis-latex` - Ebben a mappában található a jelen dokumentum LaTeX kódja és a beszúrt ábrák.

A mellékelt, projekt közben elkészített szoftverek részletes bemutatása a Melléklet B: Szoftverek részben található.

2.3. Mellékletek

A munka során minden lépésnél tudatosan olyan programokat készítettem melyek segítségével a lehető legtöbb metrikát rögzítettem és minden metrikáról vizualizációt is készítettem. Ez az anyag terjedelmében túlságosan hosszú a diplomamunkához, így mellékleteket készítettem amikbe elhelyeztem a mérési adatokat és vizualizációikat

szépen formázott és rendezett alakban, valamint egy másik mellékletben bemutatam az elkészített szoftvereket részletesen, kiemelve azok érdekesebb részleteit. Ezek a mellékletek az alábbiak.:

2.3.1. Melléklet A: Mérési napló

A mérési napló a diplomamunka melléklete ami minden a munka során elvégzett mérést és ezek eredményeit teljes terjedelmében tartalmazza. Az adatbázis és annak építésének ismertetése, a mérések menete, az alkalmazott metrikák leírása és a modellek ismertetése a diplomamunka adott fejezében található. A mérési napló a tiszta mérési adatokat és ezek vizualizációit tartalmazza.

2.3.2. Melléklet B: Szoftverek

A diplomamunka során elkészített szoftverek központi szerepet játszottak az adatfeldolgozásban, a tanítási és tesztelési folyamatok automatizálásában, valamint a mért adatok kiértékelésében. A teljes munkafolyamat Python nyelven készült, Jupyter notebookok, PyTorch keretrendszer, valamint a matplotlib, seaborn, pandas és numpy könyvtárak használatával. A modellek betanítása és kiértékelése saját fejlesztésű kódbázison történt, amely lehetővé tette az egyedi igények szerinti metrika- és grafikon-előállítást.

A fejlesztett szoftvermodulok a következő főbb komponensekre bonthatók:

Adat-előkészítő és konvertáló eszközök: Ezek a programrészek a nyers fotóállományból készítettek előfeldolgozott, egységesített és annotált képadatbázist. Ide tartozik az EXIF-adatok megőrzését biztosító átalakítás, a fájlnev-alapú címkézés, a képméretre vágás, tömörítés, valamint a tanító/tesztelő/validáló halmazok létrehozása.

Modellek tanítását vezérlő szkriptek: A tanítórendszer lehetővé teszi különféle modellek (ResNet50, DenseNet121, EfficientNet-B0, ConvNeXt-Tiny, stb.) betöltését, finomhangolását, valamint többféle tanítási fázis (pl. teljes tanítóhalmaz, iteratív bővítés) automatizálását. A szkriptek rögzítik az összes fontos tanítási metrikát (loss, accuracy, precision, recall, F1-score), epochonként és osztályszinten.

Tesztelési és kiértékelő modulok: Ezek a programok lehetővé teszik a betanított vagy gyári súlyokkal rendelkező modellek teljesítményének összehasonlítását különféle metrikák alapján, mind Top-1, Top-5, mind osztályszpecifikus pontosság szerint.

A program automatikusan készít confusion matrixokat, osztályeloszlás-görbéket, metrika-idő vagy metrika-mintaszám függvényeket.

Vizualizációs alrendszer: A metrikák kiértékelését követően a rendszer képes automatikusan egységes formátumú és jól olvasható grafikonokat generálni. A matplotlib és seaborn könyvtárakkal készült diagramok a tanítási folyamat vizuális dokumentációját nyújtják, megkönnyítve az összehasonlítást.

Egyedi fejlesztésű kis modell és fejrész prototípusok: A szoftvercsomag része az erőforrás-kímélő, ResNet18-alapú lokális modell fejlesztését támogató kódbázis is, amely lehetővé teszi különféle hálózati „fejek” tesztelését és kiértékelését. Ezek külön paramétereizhetők és egységes módon mérhetők a többi modellhez hasonlóan. Minden programrész jól dokumentált, verziókövetett formában készült, a főbb beállítások és paraméterek külön konfigurációs állományban találhatók. A melléklet tartalmazza a szoftverrendszer logikai felépítésének leírását, a legfontosabb fájlok magyarázatát, valamint a kód működésének szemléltetését példákkal.

2.4. A feladat

A dolgozat célja egy saját készítésű, nagyméretű, természetes környezetben gyűjtött fotókból álló képadatbázis létrehozása és ezen különféle mély neurális hálózatok képosztályozási teljesítményének vizsgálata. A vizsgálat középpontjában az áll, hogy a valós, hosszú farok eloszlású osztályeloszlással rendelkező adathalmazok milyen kihívásokat jelentenek a korszerű képfeldolgozó modellek számára, valamint hogy ezek a modellek milyen mértékben képesek adaptálódni az adatok mennyiségének és kiegyensúlyozatlanságának változásaihoz.

A dolgozat során egy 180 750 képből álló, saját fotóimból összeállított és kétféle címkézési sémával (ImageNet1K és Places365) ellátott adatbázist készítettem. Ezt követően több ismert mélytanulási architektúra – többek között ResNet50, EfficientNet-B0, ViT-B/16 és ConvNeXt-Tiny – teljesítményét értékeltem három fázisban: előtanítás nélküli, teljes tanításon átesett, valamint növekvő méretű tanítóhalmazon történő tanítás után. Az eredményeket több metrika mentén, például Top-1 és Top-5 pontosság, Precision, Recall és F1-score segítségével elemeztem.

Emellett célom volt egy saját, erőforrástakarékos modell megalkotása is, amely kis méretű, lokális alkalmazásokban – például mobil eszközökön – hatékonyan használható, miközben teljesítménye megközelíti a nagyobb méretű, általános célú model-

lekét.

2.4.1. Képosztályozás mint feladat

A képosztályozás (image classification) a számítógépes látás egyik alapvető problémája, amelynek célja, hogy egy bemeneti képről automatikusan eldöntsük, melyik előre definiált osztályba tartozik. Ez a feladat különösen fontos számos gyakorlati alkalmazásban, például arcfelismerés, orvosi képelemzés, önvezető járművek környezeti értelmezése vagy digitális fotóarchívumok rendezése esetén.

A klasszikus képosztályozási megközelítések során jellemzően kézzel készített jellemzők (például élek, színek, textúrák) segítségével történt az osztályba sorolás. Azonban a mélytanulás, különösen a konvolúciós neurális hálózatok (CNN-ek) megjelenése forradalmasította ezt a területet: ezek a modellek képesek automatikusan megtanulni a képek releváns reprezentációit, így jelentősen javítva a pontosságot.

A képosztályozás során a neurális hálózat bemenete egy fix méretű kép, a kimenete pedig egy valószínűségi eloszlás az osztályok között, amelyből kiválasztható a legvalószínűbb címke. A feladat kihívásai közé tartozik az osztályok közti hasonlóság, a képi tartalom sokfélesége, a világítás, szögtorzítás, háttér és egyéb zavaró tényezők, valamint az osztályeloszlások kiegyensúlyozatlansága, amely különösen a valós adathalmazok esetén gyakori.

A hosszú farok (long-tail) eloszlás külön figyelmet igényel a képosztályozásban, mivel az adatok túlnyomó része néhány gyakori kategóriára koncentrálódik, míg a legtöbb osztály csak kis számú mintával szerepel. Az ilyen disztribúciók kezelése különösen nehéz feladat a tanuló modellek számára, mivel a hagyományos algoritmusok hajlamosak alultanulni a ritkább osztályokat.

A képosztályozási feladat tehát nem csupán technikai kihívás, hanem kulcsfontosságú építőelem sok mesterséges intelligencia alapú rendszer számára. A jelen dolgozatban bemutatott vizsgálatok célja, hogy feltérképezzék, hogyan viselkednek a különféle modern neurális hálózati architektúrák, amikor valós, nem szintetikus kiegyensúlyozott adatokkal kell megbirkózniuk.

2.4.2. A konvolúciós neurális hálózatok mint megoldás

A konvolúciós neurális hálózatok (CNN-ek, azaz Convolutional Neural Networks) az utóbbi évtizedben a gépi látás és képfeldolgozás egyik legmeghatározóbb eszközévé

váltak. A hagyományos, teljesen összekötött (fully connected) neurális hálózatokkal szemben a CNN-ek képesek kihasználni a képek térbeli struktúráját, és ennek köszönhetően hatékonyabban tanulnak vizuális jellemzőket.

A CNN-ek alapötlete a lokális jellemzők felismerésén alapszik: a bemeneti képen végighaladó konvolúciós szűrők képesek detektálni alacsony szintű mintázatokat, például éleket, sarkokat vagy textúrákat. Az egymásra épülő rétegek révén a hálózat egyre összetettebb vizuális absztrakciókat tanul meg, amelyek végső soron lehetővé teszik az osztályok közötti különbségek felismerését.

A konvolúciós rétegeket gyakran követik aktivációs (pl. ReLU), majd pooling rétegek, amelyek a méretcsökkentést és a jellemzők invarianciáját biztosítják. A hálózat végén egy vagy több teljesen összekötött réteg található, amely a tanult jellemzők alapján dönt az osztályokhoz való hozzárendelésről. A tanítási folyamat a hibák visszaterjesztésén (backpropagation) és gradiensalapú optimalizáción alapszik.

A CNN-ek sikerének egyik kulcsa az, hogy nem igényelnek kézzel definiált jellemzőkészleteket - a hálózat maga tanulja meg az optimális reprezentációkat a bemeneti adatokból. Ez különösen előnyös olyan esetekben, ahol a képek nagy változatosságot mutatnak, vagy ahol nem áll rendelkezésre szakértői tudás a jellemzők kézi kiválasztásához.

Az elmúlt évek során számos jól ismert CNN-alapú architektúra született (például LeNet, AlexNet, VGG, ResNet, DenseNet, EfficientNet, stb.), amelyek mind különféle technikai újításokat vezettek be a hálózatok mélysége, számítási hatékonysága vagy tanulási képességei terén. A jelen dolgozat több ilyen, különféle generációba tartozó modellt is vizsgál, hogy összehasonlíthatóvá váljon teljesítményük egy valós, természetes képekből álló, kiegyensúlyozatlan eloszlású adathalmazon.

2.4.3. Képadatbázisok mint tanító eszközök

A gépi tanulási rendszerek, különösen a mély neurális hálózatok sikerességének egyik kulcsa a megfelelő mennyiségű és minőségű tanítóadat megléte. A képosztályozási feladatok esetén ez különösen fontos, hiszen a neurális hálózatok képesek milliányi paramétert megtanulni, de ehhez nagyméretű, változatos és jól strukturált képadatbázisokra van szükség. Az ilyen adathalmazok nemcsak a modellek hatékony tanítását teszik lehetővé, hanem azok általánosító képességét is alapvetően meghatározzák. Számos nyílt képadatbázis - mint például az ImageNet, a CIFAR-10, a MNIST vagy

a Places365 - alapvető szerepet játszott a mesterséges intelligencia fejlődésében, mivel ezek standardizált környezetet biztosítottak a modellek tanításához és összehasonlításához. Azonban ezek az adathalmazok gyakran laboratóriumi környezetben előállított, válogatott és sokszor mesterségesen kiegyensúlyozott mintákból állnak, ami korlátozza az általános életszerű alkalmazásokra való felkészítést.

A valós világ képei gyakran heterogének, torzítottak, zajosak, és az osztályok eloszlása erősen aszimmetrikus. Az ilyen „long-tail” eloszlású adatbázisok, ahol sok kategória kevés példánnyal szerepel, komoly kihívást jelentenek a tanuló algoritmusok számára. Az ezekkel való munka viszont közelebb hozza a neurális modellek viselkedését a valódi alkalmazási környezetekhez, ahol az adatok ritkán ideálisak.

A dolgozatban bemutatott egyedi képadatbázis - az SBphotothemes180k - egy különleges erőforrás, mivel saját fotógyűjteményből származik, természetes módon jött létre, és hosszú időszak alatt, különféle helyszíneken, változatos körülmények között készült képeket tartalmaz. Ez a típusú adathalmaz ideális arra, hogy feltérképezzük, hogyan teljesítenek a neurális hálózatok nem laboratóriumi környezetből származó, organikus képadatokon.

Egy jól megtervezett képadatbázis nemcsak a tanítás során nyújt alapot, hanem lehetőséget teremt arra is, hogy vizsgáljuk a modellek robusztusságát, általánosítási képességét, valamint azt, hogyan reagálnak az adatok mennyiségi vagy minőségi változásaira. Ezért a képadatbázis nem csupán háttéranyag, hanem aktív és kulcsfontosságú szereplője a neurális hálózatokkal végzett kutatómunkának.

2.5. Irodalomkutatás

A diplomamunka elkészítése során elsősorban a képzés során végzett Bevezetés a gépi tanulásba, Gépi tanulás alapjai Python-ban és Deep Learning kurzusokon tanultakra támaszkodtam, de a munka kezdete előtt olvastam a felhasznált modelleket bemutató cikkeket, survey cikkeket és a témába vágó egyéb írásokat. Ebben a részben ezeket szeretném bemutatni. (A felhasznált irodalmak listája a projekt GitHub könyvtárában is megtalálható.)

2.5.1. A metrikák

Az alkalmazott metrikák megértésében és kiválasztásában nagy segítségemre volt az "Image Classification with Convolutional Neural Networks"[`article\_cnn\_metrics`] című írás.

2.5.2. Áttekintő írások

Az irodalomkutatást áttekintő művek keresésével és értelmezésével kezdtem.

- "A Survey of Convolutional Neural Networks: Analysis, Applications, and Prospects"[`article\_cnn\_survey`]
- "Review of deep learning: concepts, CNN architectures, challenges, applications, future directions"[`article\_dl\_survey`]
- "Understanding Deep Convolutional Networks"[`article\_cnn\_math`]
- "Benchmarking Neural Network Training Algorithms"[`article\_benchmarking`]

2.5.3. A modellek és adathalmazok cikkei

Természetesen nagyon nagy segítséget jelentettek a felhasznált modelleket és kategorizálásokat ismertető írások. Ezek az írások a következők:

- A ResNet50 modell ismertetése.[`article\_resnet50`]
- DenseNet121 modell ismertetése.[`article\_densenet`]
- EfficientNet-B0 modell ismertetése.[`article\_efficientnet`]
- ConvNeXt-Tiny modell ismertetése.[`article\_convnext`]
- ViT-B/16 modell ismertetése.[`article\_vit\_b16`]
- Inception-v3 modell ismertetése.[`article\_inception\_v3`]
- NASNet modell ismertetése.[`article\_nasnet`]
- ImageNet1K osztályozás ismertetése.[`article\_ImageNet1K`]
- Places365 osztályozás ismertetése.[`article\_places365`]

2.5.4. Optimalizációs módszerek

Amikor az új modellt terveztem több optimalizációs megoldásnak is utánanéztem. Az alábbiakban az ezekhez tartozó irodalmakat sorolom fel.

- GELU (Gaussian Error Linear Unit) aktivációs függvény[`article\_GELU`]
- Layer Normalization[`article\_LayerNorm`]
- Dropout regulárizáció[`article\_dropout`]
- Batch Normalization (BatchNorm)[`article\_BatchNorm`]
- Adaptive Average Pooling (AdaptiveAvgPool2d)[`article\_AdaptiveAvgPool2d`]

2.5.5. Egyéb irodalom

A további cikkek és írások amiket áttekintettem a munka megkezdése előtt az alábbiak:

- "A Survey on Deep Transfer Learning and Beyond"[`article\_Survey\_Deep\_Transfer`]
- "Landscape photo classification mechanism for context-aware photography support system" [`article\_Landscape\_photo\_classification`]
- "Photo Content Classification Using Convolutional Neural Network" [`article\_Photo\_Content\_Classification`]
- "An Analysis Of Convolutional Neural Networks For Image Classification"[`article\_cnn\_image\_class`]

3. fejezet

Saját képadatbázis építése

3.1. A forrásképek

3.1.1. Motiváció

3.1.2. Források

3.2. Forrás adathalmaz elemzése

3.2.1. Darabszámok

3.2.2. Méretek

3.2.3. Kategóriák

3.3. Adatbázis szerkezete

3.3.1. Képméret, formátum

3.3.2. Mappaszerkezet

3.3.3. Kategóriák

3.3.4. Osztályozás

3.4. Előfeldolgozás

3.4.1. Kötegelt adatgyűjtés

3.4.2. Méret és teljesítmény korlátok

3.5. Saját feldolgozó futószalag

3.5.1. Tulajdonságok

3.5.2. Szkript futószalag

Konvertálás

Méretezés

4. fejezet

Modellek és metrikák kiválasztása

4.1. Metodika

4.2. Kiválasztott modellek

4.2.1. ResNet50

4.2.2. DenseNet121

4.2.3. EfficientNet-B0

4.2.4. ConvNeXt-Tiny

4.2.5. ViT-B/16

4.2.6. Inception-v3

4.2.7. NASNet

4.3. A kiválasztott metrikák:

4.3.1. Top-1 pontosság

4.3.2. Top-5 pontosság

4.3.3. Precision

4.3.4. Recall

4.3.5. F1-score

4.3.6. Train és Val loss

4.3.7. Train és Val pontosság

4.4. Összegzés

5. fejezet

Vizsgálati metodika

5.1. I. Fázis: Tanítás nélküli tesztelés

5.2. II. Fázis: Teljes tanítás

5.3. III. Fázis: Iteratív tanítás

5.4. IV. Fázis: Saját modell fejlesztése

6. fejezet

Szoftveres környezet

6.1. Lokális vagy Online

6.2. Google Colab lehetőségek

6.3. Tárolási problémák

6.4. Tanító és tesztelő programok

6.4.1. Tesztelés

6.4.2. Tanítás

6.4.3. Mérés

6.4.4. Problémák és megoldások

Sablon notebook-ok

LaTeX táblázatok

Confusion mátrixok

NASNet optimalizáció

6.5. Összefoglalás

7. fejezet

I. Fázis: Tanítás nélküli tesztelés

7.1. ResNet50

7.2. DenseNet121

7.3. EfficientNet-B0

7.4. ConvNeXt-Tiny

7.5. ViT-B/16

7.6. Inception-v3

7.7. NASNet

7.8. Összefoglaló

8. fejezet

II. Fázis: Teljes tanítás

8.1. ResNet50

8.2. DenseNet121

8.3. EfficientNet-B0

8.4. ConvNeXt-Tiny

8.5. ViT-B/16

8.6. Inception-v3

8.7. NASNet

8.8. Összefoglaló

9. fejezet

III. Fázis: Iteratív tanítás

9.1. ResNet50

9.2. DenseNet121

9.3. EfficientNet-B0

9.4. ConvNeXt-Tiny

9.5. ViT-B/16

9.6. Inception-v3

9.7. NASNet

9.8. Összefoglaló

10. fejezet

IV. Fázis: Saját modell fejlesztése

10.1. A ResNet18

10.2. A Base fej

10.3. A Deep fej

10.4. A Hybrid-v1 fej

10.5. A Hybrid-v2 fej

10.6. Mérések

10.6.1. I. Fázis: Tanítás nélküli tesztelés

10.6.2. II. Fázis: Teljes tanítás

10.6.3. III. Fázis: Iteratív tanítás

10.7. Összefoglalás

11. fejezet

Legfontosabb eredmények

12. fejezet

Összefoglaló

A dolgozat célja a fotó osztályozási probléma vizsgálata volt neurális hálózatokkal saját nagyméretű címkézett adatbázison. A vizsgálat során összegyűjtöttem 180750 egyedi fotót az elmúlt 20 év saját készítésű képeiből, ebből címkézett adatbázist készítettem SBphotothemes180k néven kétféle címkézéssel. Az ImageNet1K címkékből 114 kategória adta az első osztályozást a 300 képnél kisebb osztályok megszüntetése után, a Places365 címkékből 121 kategória adta a második osztályozást. Ezek után 80-10-10 arányban felosztottam tanító, validáló és tesztelő adathalmazra az adatbázist. Az adathalmaz képeit 224*244 méretű négyzetes jpg 80 tömörítésű képekké konvertáltam. Így a közel 2TB mennyiségű forrásképből nagyjából 10GB méretű adatbázis készült. Az elkészült adatbázison vizsgáltam az osztályozási eloszlásokat, és az EXIF adatokat. Az osztályozások estén az átlagos osztályméret 1500 kép körül alakult, a medián 1000 kép körül alakult ami jó, de mivel természetes adatokról beszélünk, így az aszimmetria magas, 8.4 és a szórás is magas 3200 körüli tehát tipikus Long-tail eloszlást mutat. Az EXIF adatok konverzió közbeni megőrzése és elemzése különösen fontos volt a részletes statisztikák elvégzéséhez és a későbbi vizsgálatok lehetőségeinek biztosításához. Az így elkészített adatbázis segítségével három fázisos vizsgálatot végeztem hét ismert és gyakran használt modellen. Ezek a modellek a ResNet50, DenseNet121, EfficientNet-B0, ConvNeXt-Tiny, ViT-B/16, Inception-v3, NASNet voltak. Az alkalmazott metrikák a következők lettek: Top-1 és Top-5 pontosság, Precision, Recall, F1-score. Ezeken túl vizsgáltam a tanítás közbeni validációs és tanítási pontosságokat. Mindhárom vizsgálatot ugyanazon az adathalmazon végeztem, de más-más tanítóhalmazzal tanítottam. A három vizsgálati fázis a tanítás nélküli tesztelés, majd a teljes tanítás utáni vizsgálat volt, végül az iteratívan

növekvő tanítóhalmaz vizsgálata következett. A vizsgálat első lépése a tanítás nélküli modellek tesztelése volt a beépített súlyokkal. Ekkor a modellek 50% körüli Top 1 és 80% körüli Top 5 pontosságot és 40% körüli Precision-t nyújtottak. Itt a ConvNeXt-Tiny és ViT-B/16 emelkedtek ki. A második fázis során a teljes 144000 képes tanítóhalmazon tanítottam minden modellt 10 epoch-on keresztül. Ekkor a modellek 75% körüli Top 1 és 90% körüli Top 5 pontosságot és 70% körüli Precision-t nyújtottak a EfficientNet-B0 és NASNet emelkedtek ki. Az utolsó vizsgálat során mindig a tanítatlan modellről indulva 1000, 5000, 10000, 25000 képes tanítóhalmazon vizsgáltam a modelleket szintén 10 epoch-on keresztül. Az adataink alapján a ConvNeXt-Tiny és az EfficientNet-B0 modellek kiemelkedtek 25000 mintaszámmal történő tanítás után, míg a ResNet50 és DenseNet121 modellek gyengébben teljesítettek az alacsonyabb mintaszámokon, de növekvő mintaszámmal jelentős javulást mutattak. Eközben az Inception-v3 és a ViT-B/16 pedig a kis adathalmazon mutatott pontosság terén emelkedtek ki. Ezután megkíséreltem elkészíteni egy kis méretű, lokális alkalmazásra optimalizált erőforrástakarékos modellt a ResNet18-ra építve egy saját fejrész kifejlesztésével. Ennek során 4 modellt készítettem, egy egyrétegű, egy mély, és két modern fejrésszel rendelkezőt. Ezen a négy modellen is elvégeztem a fent ismertetett három mérési fázist. Az egyrétegű fej meglepően jól teljesített, a mély fejrész viszont jelentősen alulmaradt a fenti metrikákban, a modern fejrész csak kicsit nyújtott nagyobb pontosságot, mint az egyrétegű, de jelentősen gyorsabban futott. Összességében a kifejlesztett modell csak kis mértékben maradt alul a vizsgált hatalmas modellektől, de futási teljesítménye sokkal jobb azokénál így nem pontosságkritikus, de erőforráskímélő megoldásokhoz, például hordozható eszközök számára ideális. Összességében a nagyméretű adathalmaz, a többféle osztályozás, a nagy mennyiségű mért adat és a saját modellek további vizsgálatok alapját képezhetik a jövőben.

13. fejezet

Befejezés

13.0.1. További lehetőségek

Irodalomjegyzék

- [1] Alfonso Ramos Michel és tsai. *Image Classification with Convolutional Neural Networks*. 2021. júl., 445–473. old. ISBN: 978-3-030-70541-1. DOI: 10.1007/978-3-030-70542-8_18.
- [2] Zewen Li és tsai. „A Survey of Convolutional Neural Networks: Analysis, Applications, and Prospects”. *arXiv preprint arXiv:2004.02806* (2020).
- [3] Laith Alzubaidi és tsai. „Review of deep learning: concepts, CNN architectures, challenges, applications, future directions”. *Journal of Big Data* 8.1 (2021), 53. old.
- [4] Stéphane Mallat. „Understanding Deep Convolutional Networks”. *arXiv preprint arXiv:1601.04920* (2016).
- [5] MLCommons Algorithms Working Group. *Benchmarking Neural Network Training Algorithms*. <https://arxiv.org/html/2306.07179>. 2023.
- [6] Kaiming He és tsai. „Deep Residual Learning for Image Recognition”. *arXiv preprint arXiv:1512.03385* (2015).
- [7] Gao Huang és tsai. „Densely Connected Convolutional Networks”. *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2017, 4700–4708. old.
- [8] Mingxing Tan és Quoc V Le. „EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks”. *International Conference on Machine Learning*. PMLR. 2019, 6105–6114. old.
- [9] Zhuang Liu és tsai. „A ConvNet for the 2020s”. *arXiv preprint arXiv:2201.03545* (2022).
- [10] Alexey Dosovitskiy és tsai. „An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale”. *arXiv preprint arXiv:2010.11929* (2020).

- [11] Christian Szegedy és tsai. „Rethinking the Inception Architecture for Computer Vision”. *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2016, 2818–2826. old.
- [12] Barret Zoph és tsai. „Learning Transferable Architectures for Scalable Image Recognition”. *arXiv preprint arXiv:1707.07012* (2017).
- [13] Jia Deng és tsai. „ImageNet: A Large-Scale Hierarchical Image Database”. *2009 IEEE Conference on Computer Vision and Pattern Recognition*. IEEE. 2009, 248–255. old.
- [14] Bolei Zhou és tsai. „Places: A 10 million Image Database for Scene Recognition”. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. 2017, 1452–1460. old.
- [15] Dan Hendrycks és Kevin Gimpel. „Gaussian Error Linear Units (GELUs)”. *arXiv preprint arXiv:1606.08415* (2016).
- [16] Jimmy Lei Ba, Jamie Ryan Kiros és Geoffrey E Hinton. „Layer Normalization”. *arXiv preprint arXiv:1607.06450* (2016).
- [17] Nitish Srivastava és tsai. „Dropout: A Simple Way to Prevent Neural Networks from Overfitting”. *Journal of Machine Learning Research*. 15. köt. 2014, 1929–1958. old.
- [18] Sergey Ioffe és Christian Szegedy. „Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift”. *Proceedings of the 32nd International Conference on Machine Learning*. 2015, 448–456. old.
- [19] Kaiming He és tsai. „Spatial Pyramid Pooling in Deep Convolutional Networks for Visual Recognition”. *European Conference on Computer Vision*. 2014, 346–361. old.
- [20] Y. Zhang, S. Wang és Y. Liu. „A Survey on Deep Transfer Learning and Beyond”. *Mathematics* 10.19 (2022), 3619. old.
- [21] Nuttapoom Amornpashara és tsai. „Landscape photo classification mechanism for context-aware photography support system”. *2015 IEEE International Conference on Consumer Electronics (ICCE)*. 2015, 663–666. old. DOI: 10.1109/ICCE.2015.7066570.

- [22] Yilin Hou. „Photo Content Classification Using Convolutional Neural Network”. *Journal of Physics: Conference Series* 1651.1 (2020. nov.), 12179. old. DOI: 10.1088/1742-6596/1651/1/012179. URL: <https://dx.doi.org/10.1088/1742-6596/1651/1/012179>.
- [23] Neha Sharma, Vibhor Jain és Anju Mishra. „An Analysis Of Convolutional Neural Networks For Image Classification”. *Procedia Computer Science* 132 (2018. jan.), 377–384. old. DOI: 10.1016/j.procs.2018.05.198.

Ábrák jegyzéke

Táblázatok jegyzéke

Forráskódjegyzék