



EÖTVÖS LORÁND TUDOMÁNYEGYETEM

INFORMATIKAI KAR

INFORMÁCIÓS RENDSZEREK TANSZÉK

Fotográfiai témafelismerés neurális hálózatokkal nagy adathalmazon.

Témavezető:

Dr. Kiss Attila Elemér

Habilitált docens, tanszékvezető

Szerző:

Sándor Balázs

Programtervező informatikus MSc

Budapest, 2025

DIPLOMAMUNKA TÉMABEJELENTŐ

Hallgató adatai:

Név: Sándor Balázs

Neptun kód: AZA6NL

Képzési adatok:

Szak: programtervező informatikus, mesterképzés (MA/MSc)

Tagozat : Nappali

Belső témavezetővel rendelkezem

Témavezető neve: Dr. Kiss Attila Elemér

munkahelyének neve, tanszéke: ELTE IK, Információs rendszerek Tanszék

munkahelyének címe: 1117, Budapest, Pázmány Péter sétány 1/C.

beosztás és iskolai végzettsége: beosztás: habilitált docens tanszékvezető, végzettség: matematikus

A diplomamunka címe: Fotográfiai témafelismerés neurális hálózatokkal nagy adathalmazon.

A diplomamunka témája:

(A témavezetővel konzultálva adja meg 1/2 - 1 oldal terjedelemben diplomamunka témájának leírását)

Fotográfiai témafelismerés neurális hálózatokkal nagy adathalmazon.

A dolgozat témája, a fotográfiai témák neurális hálózatokkal történő felismerése.

Saját nagyméretű fotóadatbázisomból a neurális hálózatok tanításához szükséges címkézett, konvertált, átméretezett fotóadatbázist készítek és elkészítem ennek leíró statisztikáit, hogy összehasonlítható legyen más tanító adathalmazokkal.

Összegyűjtöm a témában született korábbi írásokban alkalmazott mérési módszereket és metrikákat melyek az összehasonlítás alapját képezik majd.

Osztályozási feladatként, szükséges a célosztályok meghatározása, melyet a korábbi írásokban alkalmazott osztályok és a lokális adathalmaz sajátosságainak összefűlésével készítek el.

A korábbi írások alapján összegyűjtöm a szabadon elérhető modelleket és témafelismerési eljárásokat majd ezeket alkalmazom a saját nagyméretű adatbázisomra és az említett metrikák alapján összehasonlítom őket, majd saját megoldást készítek a korábbiak felhasználásával és ezt a meghatározott mérőszámok szerint összevetem a meglévőkkel.

Az írás célja a megismert módszerek közül a meghatározott metrikák szerinti legjobb megoldás meghatározása, ezek kombinálása, fejlesztése és az új megoldás eredményeinek összevetése a korábbiakkal. Vizsgálat tárgya még a nagy adathalmaz hatásainak vizsgálata a meglévő modellek minőségére és performanciájára.

Budapest, 2024. 05. 22.

Tartalomjegyzék

1. Absztrakt	6
2. Bevezető	7
2.1. Motiváció	8
2.2. Elérhetőség	9
2.2.1. Adatok elérhetősége	9
2.2.2. Finomhangolt modellek elérhetősége	10
2.2.3. Programkódok elérhetősége	10
2.3. Mellékletek	11
2.3.1. Melléklet A: Mérési napló	12
2.3.2. Melléklet B: Szoftverek	12
2.4. A feladat	14
2.4.1. Képosztályozás mint feladat	14
2.4.2. A konvolúciós neurális hálózatok mint megoldás	15
2.4.3. Képadatbázisok mint tanító eszközök	16
2.5. Irodalomkutatás	17
2.5.1. A metrikák	17
2.5.2. Áttekintő írások	18
2.5.3. A modellek és adathalmazok cikkei	18
2.5.4. Optimalizációs módszerek	19
2.5.5. Egyéb irodalom	19
3. Saját képadatbázis építése	20
3.1. A forrásképek	21
3.1.1. Motiváció	21
3.1.2. Források	22
3.2. Forrás adathalmaz elemzése	24
3.2.1. Darabszámok	24

3.2.2.	Méretek	24
3.2.3.	Kategóriák	24
3.3.	Adatbázis szerkezete	24
3.3.1.	Képméret, formátum	24
3.3.2.	Osztályozás	24
3.3.3.	Kategóriák	24
3.3.4.	Mappaszerkezet	24
3.4.	Előfeldolgozás	24
3.4.1.	Kötegetelt adatgyűjtés	24
3.4.2.	Méret és teljesítmény korlátok	24
3.5.	Saját feldolgozó futószalag	24
3.5.1.	Tulajdonságok	24
3.5.2.	Szkript futószalag	24
3.5.3.	Performancia	24
3.5.4.	Automata osztályozás	24
3.5.5.	Places365	24
3.5.6.	ImageNet1K	24
3.5.7.	Kézi osztályozás	24
3.5.8.	Véglegesítés	24
3.6.	Utőfeldolgozás	24
3.6.1.	Kézi Adattisztítás, szűrés, törlés	24
3.6.2.	Alkategóriák elminiálása	24
3.6.3.	300 kép alatti kategóriák megszüntetése	24
3.6.4.	A rendezés finomítása, kézi és automata	24
3.6.5.	Arcfelismerés	24
3.6.6.	Nagy kategóriák szétosztása	24
3.6.7.	Üres kategóriák megszüntetése	24
3.7.	Kész adatbázis elemzése	24
3.8.	Statisztikák	24
3.8.1.	Darabszámok, méretek	24
3.8.2.	Mappavizsgáló szkript	24
3.8.3.	Kategóriák, statisztikák, méretek	24
3.8.4.	EXIF Statisztika szkript	24
3.8.5.	EXIF statisztika	24

3.9. Az elkészült adatbázis értékelése	24
4. Modellek és metrikák kiválasztása	25
4.1. Metodika	26
4.2. Kiválasztott modellek	26
4.2.1. ResNet50	26
4.2.2. DenseNet121	26
4.2.3. EfficientNet-B0	26
4.2.4. ConvNeXt-Tiny	26
4.2.5. ViT-B/16	26
4.2.6. Inception-v3	26
4.2.7. NASNet	26
4.3. A kiválasztott metrikák:	26
4.3.1. Top-1 pontosság	26
4.3.2. Top-5 pontosság	26
4.3.3. Precision	26
4.3.4. Recall	26
4.3.5. F1-score	26
4.3.6. Train és Val loss	26
4.3.7. Train és Val pontosság	26
4.4. Összegzés	26
5. Vizsgálati metodika	27
5.1. I. Fázis: Tanítás nélküli tesztelés	27
5.2. II. Fázis: Teljes tanítás	27
5.3. III. Fázis: Iteratív tanítás	27
5.4. IV. Fázis: Saját modell fejlesztése	27
6. Szoftveres környezet	28
6.1. Lokális vagy Online	28
6.2. Google Colab lehetőségek	28
6.3. Tárolási problémák	28
6.4. Tanító és tesztelő programok	28
6.4.1. Tesztelés	28
6.4.2. Tanítás	28

6.4.3. Mérés	28
6.4.4. Problémák és megoldások	28
6.5. Összefoglalás	28
7. I. Fázis: Tanítás nélküli tesztelés	29
7.1. ResNet50	29
7.2. DenseNet121	29
7.3. EfficientNet-B0	29
7.4. ConvNeXt-Tiny	29
7.5. ViT-B/16	29
7.6. Inception-v3	29
7.7. NASNet	29
7.8. Összefoglaló	29
8. II. Fázis: Teljes tanítás	30
8.1. ResNet50	30
8.2. DenseNet121	30
8.3. EfficientNet-B0	30
8.4. ConvNeXt-Tiny	30
8.5. ViT-B/16	30
8.6. Inception-v3	30
8.7. NASNet	30
8.8. Összefoglaló	30
9. III. Fázis: Iteratív tanítás	31
9.1. ResNet50	31
9.2. DenseNet121	31
9.3. EfficientNet-B0	31
9.4. ConvNeXt-Tiny	31
9.5. ViT-B/16	31
9.6. Inception-v3	31
9.7. NASNet	31
9.8. Összefoglaló	31
10. IV. Fázis: Saját modell fejlesztése	32

10.1. A ResNet18	32
10.2. A Base fej	32
10.3. A Deep fej	32
10.4. A Hybrid-v1 fej	32
10.5. A Hybrid-v2 fej	32
10.6. Mérések	32
10.6.1. I. Fázis: Tanítás nélküli tesztelés	32
10.6.2. II. Fázis: Teljes tanítás	32
10.6.3. III. Fázis: Iteratív tanítás	32
10.7. Összefoglalás	32
11. Legfontosabb eredmények	33
12. Összefoglaló	34
13. További lehetőségek	36
14. Befejezés	37
Irodalomjegyzék	38
Ábrajegyzék	41
Táblázatjegyzék	42
Forráskódjegyzék	43

1. fejezet

Absztrakt

A dolgozat célja egy nagyméretű, saját készítésű képadatbázis létrehozása és ezen mély neurális hálózatok osztályozási teljesítményének vizsgálata volt. Az SBphotothemes180k nevű adatbázis 180 750 egyedi, címkézett fényképet tartalmaz, kétféle annotációval: az ImageNet1K-ből szűrt 114, valamint a Places365-ből származó 121 kategóriával. Az osztályeloszlás erősen torzított, természetes adatok esetén tipikus, Long-tail eloszlást mutatott (aszimmetria: 8,4; szórás: 3200), de a nagy adatmennyiség és a szortírozási metodika révén kellően nagyra adódott az átlagos kategóriaméret is (1500). Az adatokon háromfázisú tesztelést végeztem hét népszerű, de különböző felépítésű neurális hálózaton (pl. ResNet50, EfficientNet-B0, ViT-B/16), különböző tanítóhalmaz-méretekkel. Az első lépés a tanítás nélküli modellek tesztelése volt a beépített súlyokkal, ezt követte a teljes tanítás, majd végül az iteratíván növekvő tanítóhalmazokon történő tesztelés. A modellek közül összességében az EfficientNet-B0 és a ConvNeXt-Tiny emelkedtek ki. A teljes adathalmazon tanított modellek közül az EfficientNet-B0 és a NASNet mutatták a legjobb teljesítményt (Top-1 pontosság 76%, Top-5 94%). Az utolsó fázisban a fokozatosan növelt tanítóhalmazokon mért teljesítményt vizsgáltam, hogy látható legyen a tanítóhalmaz méretének hatása. Ezen túl saját, erőforrástakarékos osztályozó modellt is fejlesztettem ResNet18-alapon, különféle fejrészekkel. Az egyszerű egyrétegű modell hasonló pontosságot ért el, mint az új modern fejrész, de az új modell számítási igénye jóval kisebb és pontossága összemérhető a nagy modellekével, így mobil eszközökön való alkalmazásra is alkalmas lehet. A nagyméretű adathalmaz, a többféle osztályozás, a nagy mennyiségű mért adat és a saját modellek további vizsgálatok alapját képezhetik a jövőben.

2. fejezet

Bevezető

Az utóbbi évtizedben a mesterséges intelligencia, különösen a mélytanulás (deep learning) területén tapasztalt fejlődés alapvetően átalakította a képfeldolgozás és számítógépes látás alkalmazásait. Az olyan modellek, mint a konvolúciós neurális hálózatok (CNN-ek), lehetővé tették a képek automatikus felismerését, osztályozását és tartalom szerinti csoportosítását, gyakran emberi szintű pontossággal. Az ilyen rendszerek sikere azonban nagymértékben függ a rendelkezésre álló nagy mennyiségű, jól címkézett adathalmazoktól. A legtöbb kutatás és alkalmazás olyan nyilvános benchmark adatkészleteken történik, mint az ImageNet vagy a Places365, amelyek széles körűek, de nem feltétlenül tükrözik a valós életből származó, természetes adatgyűjtés során keletkezett képek sokféleségét és osztályeloszlását. Jelen dolgozat célja egy valós, nem mesterségesen összeállított fotóadatbázison végzett osztályozási vizsgálat bemutatása. A saját készítésű, 20 év alatt összegyűlt fotógyűjteményemből kiindulva egy nagyméretű (180 750 képből álló), kétféleképpen címkézett adatbázist hoztam létre, amelyben minden kép egyedi, saját készítésű valós fotó, így ideális a természetes körülmények vizsgálatára. Az így előállított SBphotothemes180k adatbázison különböző népszerű neurális hálózatok (pl. ResNet, EfficientNet, Vision Transformer) osztályozási teljesítményét vizsgáltam többféle tanítási scenárióban, több metrika mentén. A dolgozat célja nem csupán a modellek pontosságának összehasonlítása, hanem annak feltárása, hogy milyen mértékben képesek a különböző architektúrák megbirkózni a természetes körülmények között gyűjtött adatok sokféleségével és a különféle tanítóhalmaz méretekkel. Emellett saját erőforrás-takarékos modell fejlesztésével is kísérletet tettem olyan alkalmazások számára, ahol a számítási teljesítmény korlátozott - például mobil vagy beágyazott rendszerek esetében.

2.1. Motiváció

A fényképezés számomra több mint hobbi: általános iskolás korom óta szerves része az életemnek. A fénykép egyrészt az emlékek megbízható őrzője, másrészt az önkifejezés egyedi formája is. Úgy gondolom, hogy egy jól elkészített fotó gyakran többet árul el az alkotóról, mint magáról a témáról. 2008 óta intenzíven foglalkozom fotózással, majd 2010-ben a Kalocsai Szent István Gimnázium stúdiójában, - amit Lakatos Ervin festőművész vezetett - mélyültem el a fényképezés művészi és tudatos megközelítésében. Ekkor kezdtem el a fotózást nem pusztán dokumentációs eszközként, hanem alkotói folyamatként gyakorolni. Azóta is aktívan fotózom, gyűjtöm, rendszerezem és archiválom a képeimet. A fotóim gyakran szorosan összekapcsolódnak más hobbijaimmal is: természetjárás, repülés, zene, csillagászat, valamint az állat- és növényvilág iránti érdeklődésem mind nyomot hagynak a képeimen. A vizualitás mindig is meghatározó szerepet játszott a gondolkodásomban. Programtervező informatikus alapszakos tanulmányaim során például háromdimenziós szimulációval foglalkoztam a szakdolgozatomban. A mesterképzésen - az információs rendszerek szakirányon - mélyebb betekintést nyerhettem a mesterséges intelligencia, azon belül is a mély neurális hálózatok működésébe és alkalmazási lehetőségeibe. A képzés során hamar szembesültem azzal, hogy a gépi tanulási rendszerek fejlesztésének egyik legnagyobb akadálya a minőségi, kellően címkézett adathalmazok hiánya. Ekkor tudatosult bennem, hogy az elmúlt évtizedek során saját magam által készített és gondosan karbantartott fotótár egyedülálló lehetőséget kínál egy valós, természetes környezetből származó adathalmaz kialakítására. Ez a felismerés adta a jelen diplomamunka ötletét: saját fotógyűjteményemet felhasználva egy neurális hálózatokkal végzett képosztályozási vizsgálatot hajtottam végre, amely egyszerre kapcsolódik szakmai érdeklődésemhez és személyes szenvedélyemhez is.

2.2. Elérhetőség

A munka során kiemelt figyelmet fordítottam arra, hogy minden lépést gondosan dokumentáljak, és az összes létrejött adatot – beleértve a képadatbázisokat, a finomhangolt modelleket, valamint az adatfeldolgozáshoz, tanításhoz és értékeléshez készített szoftvereket – átlátható és hozzáférhető módon elérhetővé tegyem.

Tekintettel arra, hogy a projekt során keletkezett fájlok összmérete meghaladja a 48,5 GB-ot, ezek megosztása az egyetemi OneDrive tárhelyem segítségével történt.

A projekt OneDrive mappájának elérhetősége:

https://ikelte-my.sharepoint.com/:f:/g/personal/sabuaai_inf_elte_hu/ElwbJQikJ7VJqM1u5lmhhNMBq0_falCiRZTuLwoimmdrpA?e=hGFCxI

Az elkészült szoftverek – köztük a Jupyter notebook-ok, Python és Bash szkriptek – a projekt GitHub tárhelyén érhetők el. A repository kisebb méretű, jól struktúrált, az összes a projekt során készült részletes dokumentációval ellátott fájlt tartalmazza.

Megjegyzés. A Jupyter notebook-ok megtekinthetők közvetlenül a GitHub felületén, vagy a Visual Studio Code segítségével is.

A projekt GitHub repository-jának elérhetősége:

<https://github.com/SandorBalazsHU/elte-ik-msc-thesis>

2.2.1. Adatok elérhetősége

A diplomamunkához készített és használt képadatbázisok, valamint a tanításhoz előkészített fájlok elérhetők a projekt dedikált OneDrive-mappájában. A megosztott tárhely struktúrált felépítésének célja, hogy a különböző feldolgozottsági szintű adatkészletek könnyen hozzáférhetők és újrahasznosíthatók legyenek.

A OneDrive-könyvtár főbb állományai:

- **`fine_tuned_models.zip`** (1,14 GB) – A különböző hálózati architektúrákon végzett teljes finomhangolás eredményeként létrejött modellek tömörített formában.
- **`sbphotothemes180k.zip`** (9,48 GB) – Az eredeti, kendezés nélküli, de már feldolgozott egyedi képeket tartalmazó képhalmaz, amely az SBphotothemes180k névre hallgató adatbázis alapját képezi.

- **sbphotothemes180k_imagenet114.zip** (9,48 GB) – Az SBphotothemes180k adatbázis ImageNet1K címkerendszer alapján szortírozott változata, 114 kategóriába rendezve.
- **sbphotothemes180k_imagenet114_split_80_10_10.zip** (9,48 GB) – Az előző adatbázis 80–10–10 százalékos arányban szétválasztott tanító, validáló és tesztelő halmazokra bontva, közvetlen tanításra alkalmas formában.
- **sbphotothemes180k_places121.zip** (9,48 GB) – A képhalmaz Places365 címkerendszer szerint 121 kategóriába rendezve.
- **sbphotothemes180k_places121_split_80_10_10.zip** (9,48 GB) – Az előző adatbázis tanításra előkészített változata, szintén 80–10–10 arányú Train–Val–Test bontásban.

2.2.2. Finomhangolt modellek elérhetősége

A projekt során minden, a teljes tanítóhalmazon végzett finomhangolás eredménye mentésre került, lehetővé téve a későbbi vizsgálatokat, összehasonlításokat és újrafelhasználást. Ezek a modellek szintén a OneDrive tárhelyen érhetők el:

- **fine_tuned_models.zip** (1,14 GB) – A zip-állomány a projekt során finomhangolt összes modell bináris fájljait tartalmazza.

A fájlnevek egységes és beszédes elnevezési konvenciót követnek, így egyértelműen beazonosítható, hogy az adott állomány melyik neurális hálózati modell és címkézési rendszer alapján végzett tanítás eredményeként készült.

2.2.3. Programkódok elérhetősége

A diplomamunka elkészítése során számos Jupyter notebook, Python- és Bash-alapú szkript készült, amelyek a projekt során végzett adatfeldolgozási, tanítási és kiértékelési lépéseket valósítják meg. Ezek a kódok átlátható és rendszerezett formában érhetők el a projekt GitHub-tárhelyén. A könyvtárszerkezet kialakításánál elsődleges szempont volt az olvashatóság, az átláthatóság és a könnyű navigáció.

A GitHub-repozitórium fő mappái az alábbiak:

- **literature** – Az irodalomkutatás során összegyűjtött szakirodalmi anyagokat tartalmazza.

- **notebooks** – A Google Colab környezethez készült notebookok, amelyek részletesen dokumentálják az elvégzett lépéseket. A programkód mellett az eredmények és megjegyzések is jól strukturáltan szerepelnek. Minden vizsgálati fázishoz külön mappa tartozik, valamint egy `db` nevű mappa az adatbázis építésének és elemzésének lépéseit tartalmazza. Az eredmények összegzésére szolgáló notebookok szintén itt találhatók.
- **scripts** – Ebben a mappában találhatók az elkészült segédprogramok. A `cnn` alkönyvtár a neurális hálózati modellekhez és vizsgálatokhoz kapcsolódó kódokat tartalmazza, míg a `db` mappa az adatbázis előállításához használt szkripteket foglalja magában.
- **thesis-latex** – A diplomamunka szövegének LaTeX-alapú forráskódja, valamint a beillesztett ábrák találhatók itt.

A notebookok közvetlenül megtekinthetők a GitHub felületén, illetve Visual Studio Code vagy JupyterLab segítségével teljes funkcionalitással is futtathatók és szerkeszthetők.

A projekt során készült szoftverek részletes leírása és technikai bemutatása a *Melléklet B: Szoftverek* részben található.

2.3. Mellékletek

A dolgozat elkészítése során minden lépésnél tudatosan olyan szoftveres eszközöket fejlesztettem, amelyek lehetővé tették a mérésekhez kapcsolódó metrikák részletes és pontos rögzítését, valamint azok szemléletes vizualizációját. A keletkezett adatmennyiség és ábrák száma azonban jelentősen meghaladja a diplomamunka terjedelmi korlátait, ezért az eredményeket külön mellékletekben helyeztem el.

Az egyik melléklet a mérések teljes dokumentációját, nyers adatait és azok grafikus megjelenítését tartalmazza rendezett és jól áttekinthető formában. Egy másik mellékletben az általam készített szoftvereket mutatom be részletesen, külön figyelmet fordítva a fontosabb implementációs megoldásokra és az érdekesebb technikai megvalósításokra.

Az elkészült mellékletek a következők:

2.3.1. Melléklet A: Mérési napló

A mérési napló a diplomamunka mellékleteként szolgál, és a munka során végzett valamennyi mérés részletes dokumentációját tartalmazza. Az adatbázis felépítésének és struktúrájának ismertetése, a mérések pontos menete, az alkalmazott értékelési metrikák és a vizsgált modellek jellemzése a dolgozat vonatkozó fejezeteiben olvasható.

Ebben a mellékletben a mérések eredményei nyers, de rendezett formában kerültek rögzítésre. A metrikák (Top-1, Top-5 pontosság, Precision, Recall, F1-score stb.) mellett szerepelnek a modellek teljesítményének vizuális megjelenítései is, grafikonok és táblázatok formájában. A jobb áttekinthetőség érdekében minden mérési sorozat után rövid, szöveges összefoglaló is készült, amely kiemeli a legfontosabb tapasztalatokat és tendenciákat.

A mérési napló célja a teljes átláthatóság és reprodukálhatóság biztosítása, valamint az, hogy a részletes adatokhoz való hozzáférés segítse az eredmények értelmezését és további elemzését. A mérési napló kattintható tartalomjegyzékkel rendelkezik megkönnyítendő a navigálást és a keresett adatok, grafikonok gyors elérését.

2.3.2. Melléklet B: Szoftverek

A diplomamunka során elkészített szoftverek központi szerepet játszottak az adatfeldolgozásban, a tanítási és tesztelési folyamatok automatizálásában, valamint a mért adatok kiértékelésében. A teljes munkafolyamat Python nyelven készült, Jupyter notebookok, PyTorch keretrendszer, valamint a matplotlib, seaborn, pandas és numpy könyvtárak használatával. A modellek betanítása és kiértékelése saját fejlesztésű kódbázison történt, amely lehetővé tette az egyedi igények szerinti metrika- és grafikon-előállítását.

A fejlesztett szoftvermodulok a következő főbb komponensekre bonthatók:

Adat-előkészítő és konvertáló eszközök: Ezek a programrészek a nyers fotóállományból készítettek előfeldolgozott, egységesített és annotált képadatbázist. Ide tartozik az EXIF-adatok megőrzését biztosító átalakítás, az MD hash alapú elnevezés és ismétlődés szűrés, az automatikus kategorizálás, a megfelelő képméretre vágás, tömörítés, valamint a tanító/tesztelő/validáló halmazok létrehozása.

A modellek tanítását vezérlő szkriptek: A tanítórendszer lehetővé teszi különféle modellek (ResNet50, DenseNet121, EfficientNet-B0, ConvNeXt-Tiny, stb.) betöltését,

finomhangolását, valamint többféle tanítási fázis (pl. teljes tanítóhalmaz, iteratív bővítés) automatizálását. A szkriptek rögzítik az összes fontos tanítási metrikát (loss, accuracy, precision, recall, F1-score), epochonként és osztályszinten.

Tesztelési és kiértékelő modulok: Ezek a programok lehetővé teszik a betanított vagy gyári súlyokkal rendelkező modellek teljesítményének összehasonlítását különféle metrikák alapján, mind Top-1, Top-5, mind osztályszpecifikus pontosság szerint. A program automatikusan készít confusion matrixokat, osztályeloszlás-görbéket, metrika-idő vagy metrika-mintaszám függvényeket.

Vizualizációs alrendszer: A metrikák kiértékelését követően a rendszer képes automatikusan egységes formátumú és jól olvasható grafikonokat generálni. A matplotlib és seaborn könyvtárakkal készült diagramok a tanítási folyamat vizuális dokumentációját nyújtják, megkönnyítve az összehasonlítást.

Egyedi fejlesztésű kis modell és fejrész prototípusok: A szoftvercsomag része az erőforrás-kímélő, ResNet18-alapú lokális modell fejlesztését támogató kódbázis is, amely lehetővé teszi különféle hálózati „fejek” tesztelését és kiértékelését. Ezek külön paramétereizhetők és egységes módon mérhetők a többi modellhez hasonlóan. Minden programrész jól dokumentált, verziókövetett formában készült, a főbb beállítások és paraméterek külön konfigurációs blokkokban találhatóak a notebook-okban. A virtualizált környezet kialakításáért felelős telepítő blokkok is elhelyezésre kerültek a notebook-okba a könnyebb megismételhetőség érdekében. A melléklet tartalmazza a szoftverrendszer logikai felépítésének leírását, a legfontosabb fájlok magyarázatát, valamint a kód működésének szemléltetését példákkal.

2.4. A feladat

A dolgozat célja egy saját készítésű, nagyméretű, természetes környezetben gyűjtött fotókból álló képadatbázis létrehozása és ezen különféle mély neurális hálózatok képosztályozási teljesítményének vizsgálata. A vizsgálat középpontjában az áll, hogy a valós, long-tail osztályeloszlással rendelkező adathalmazok milyen kihívásokat jelentenek a korszerű képfeldolgozó modellek számára, valamint hogy ezek a modellek milyen mértékben képesek adaptálódni az adatok mennyiségének és kiegyensúlyozatlanságának változásaihoz.

A dolgozat során egy 180 750 képből álló, saját fotóimból összeállított és kétféle címkézési sémával (ImageNet1K és Places365) ellátott adatbázist készítettem. Ezt követően több ismert mélytanulási architektúra – többek között ResNet50, EfficientNet-B0, ViT-B/16 és ConvNeXt-Tiny – teljesítményét értékeltem három fázisban: előtanítás nélküli, teljes tanításon átesett, valamint növekvő méretű tanítóhalmazon történő tanítás után. Az eredményeket több metrika mentén, például Top-1 és Top-5 pontosság, Precision, Recall és F1-score segítségével elemeztem.

Emellett célom volt egy saját, erőforrástakarékos modell megalkotása is, amely kis méretű, lokális alkalmazásokban – például mobil eszközökön – hatékonyan használható, miközben teljesítménye megközelíti a nagyobb méretű, általános célú modellekét.

2.4.1. Képosztályozás mint feladat

A képosztályozás (image classification) a számítógépes látás és képfeldolgozás egyik alapvető problémája, amelynek célja, hogy egy bemeneti képről automatikusan eldöntsük, melyik előre definiált osztályba tartozik. Ez a feladat különösen fontos számos gyakorlati alkalmazásban, például arcfelismerés, orvosi képelemzés, önvezető járművek környezeti értelmezése vagy digitális fotóarchívumok rendezése esetén. A klasszikus képosztályozási megközelítések során jellemzően előre definiált jellemzők (például élek, színek, textúrák) segítségével történt az osztályba sorolás. Azonban a mélytanulás, különösen a konvolúciós neurális hálózatok (CNN-ek) megjelenése forradalmasította ezt a területet: ezek a modellek képesek automatikusan megtanulni a képek releváns elemeit, így jelentősen javítva a pontosságot.

A képosztályozás során a neurális hálózat bemenete egy fix méretű kép, a kimenete pedig egy valószínűségi eloszlás az osztályok között, amelyből kiválasztható a leg-

valószínűbb címke. A feladat kihívásai közé tartozik az osztályok közti hasonlóság, a képi tartalom sokfélesége, a világítás, szögtorzítás, háttér és egyéb zavaró tényezők, valamint az osztályeloszlások kiegyensúlyozatlansága, amely különösen a valós adathalmazok esetén gyakori.

A long-tail eloszlás külön figyelmet igényel a képosztályozásban, mivel az adatok túlnyomó része néhány gyakori kategóriára koncentrálódik, míg a legtöbb osztály csak kisebb számú mintával szerepel de ezek összessége mégis jelentős arányt képvisel az adathalmazban. Az ilyen disztribúciók kezelése különösen nehéz feladat a tanuló modellek számára, mivel a hagyományos algoritmusok hajlamosak alultanulni a ritkább osztályokat.

A képosztályozási feladat tehát nem csupán technikai kihívás, hanem kulcsfontosságú építőelem sok mesterséges intelligencia alapú rendszer számára. A jelen dolgozatban bemutatott vizsgálatok célja, hogy feltérképezzék, hogyan viselkednek a különféle modern neurális hálózati architektúrák, amikor valós, nem szintetikus kiegyensúlyozott adatokkal kell megbirkózniuk. [1] [2] [3]

2.4.2. A konvolúciós neurális hálózatok mint megoldás

A konvolúciós neurális hálózatok (CNN-ek, azaz Convolutional Neural Networks) az utóbbi évtizedben a gépi látás és képfeldolgozás egyik legmeghatározóbb eszközévé váltak. A hagyományos, teljesen összekötött (fully connected) neurális hálózatokkal szemben a CNN-ek képesek kihasználni a képek térbeli struktúráját, és ennek köszönhetően hatékonyabban tanulnak vizuális jellemzőket.

A CNN-ek alapötlete a lokális jellemzők felismerésén alapszik: a bemeneti képen végighaladó konvolúciós szűrők képesek detektálni alacsony szintű mintázatokat, például éleket, sarkokat vagy textúrákat. Az egymásra épülő rétegek révén a hálózat egyre összetettebb vizuális absztrakciókat tanul meg, amelyek végső soron lehetővé teszik az osztályok közötti különbségek felismerését.

A konvolúciós rétegeket általában nemlineáris aktivációs függvények (például ReLU [4]) követik, melyek nemlinearitást visznek a rendszerbe, azaz segítik, hogy a háló ne csak lineáris műveleteket tanuljon meg, majd pooling rétegek [5] [6], amelyek egyrészt csökkentik a reprezentáció térbeli méretét, másrészt hozzájárulnak a jellemzők eltolás-invarianciájához (pl. ha a tárgy kis mértékben más helyen van a képen, a pooling elősegíti, hogy a jellemzők ennek ellenére hasonlóak maradjanak), ezáltal

növelve a modell általánosítási képességét. A hálózat végén egy vagy több teljesen összekötött réteg található, amely a tanult jellemzők alapján dönt az osztályokhoz való hozzárendelésről. A tanítási folyamat a hibák visszaterjesztésén (backpropagation) és gradiensalapú optimalizáción alapszik.

A CNN-ek sikerének egyik kulcsa az, hogy nem igényelnek kézzel definiált jellemző-készleteket - a hálózat maga tanulja meg az optimális reprezentációkat a bemeneti adatokból. Ez különösen előnyös olyan esetekben, ahol a képek nagy változatosságot mutatnak, vagy ahol nem áll rendelkezésre szakértői tudás a jellemzők kézi kiválasztásához.

Az elmúlt évek során számos jól ismert CNN-alapú architektúra született (például LeNet, AlexNet, VGG, ResNet, DenseNet, EfficientNet, stb.), amelyek mind különféle technikai újításokat vezettek be a hálózatok mélysége, számítási hatékonysága vagy tanulási képességei terén. A jelen dolgozat több ilyen, különféle generációba tartozó modellt is vizsgál, hogy összehasonlíthatóvá váljon teljesítményük egy valós, természetes képekből álló, kiegyensúlyozatlan eloszlású adathalmazon. [7] [3] [1]

2.4.3. Képadatbázisok mint tanító eszközök

A gépi tanulási rendszerek, különösen a mély neurális hálózatok sikerességének egyik kulcsa a megfelelő mennyiségű és minőségű tanítóadat megléte. A képosztályozási feladatok esetén ez különösen fontos, hiszen a neurális hálózatok képesek milliányi paramétert megtanulni, de ehhez nagyméretű, változatos és jól strukturált képadatbázisokra van szükség. Az ilyen adathalmazok nemcsak a modellek hatékony tanítását teszik lehetővé, hanem azok általánosító képességét is alapvetően meghatározzák. Számos nyílt képadatbázis - mint például az ImageNet [8] a CIFAR-10, a MNIST vagy a Places365 [9] - alapvető szerepet játszott a mesterséges intelligencia fejlődésében, mivel ezek standardizált környezetet biztosítottak a modellek tanításához és összehasonlításához. Azonban ezek az adathalmazok gyakran laboratóriumi környezetben előállított, válogatott és sokszor mesterségesen kiegyensúlyozott mintákból állnak, ami korlátozza az általános életszerű alkalmazásokra való felkészítést.

A valós világ képei gyakran heterogének, torzítottak, zajosak, és az osztályok eloszlása erősen aszimmetrikus. Az ilyen „long-tail” eloszlású adatbázisok, ahol sok kategória kevés példánnyal szerepel, komoly kihívást jelentenek a tanuló algoritmusok számára. Az ezekkel való munka viszont közelebb hozza a neurális modellek

viselkedését a valódi alkalmazási környezetekhez, ahol az adatok ritkán ideálisak.

A dolgozatban bemutatott egyedi képadatbázis - az SBphotothemes180k - egy különleges erőforrás, mivel saját fotógyűjteményből származik, természetes módon jött létre, és hosszú időszak alatt, különféle helyszíneken, változatos körülmények között készült képeket tartalmaz. Ez a típusú adathalmaz ideális arra, hogy feltérképezzük, hogyan teljesítenek a neurális hálózatok nem laboratóriumi környezetből származó, organikus képadatokon.

Egy jól megtervezett képadatbázis nemcsak a tanítás során nyújt alapot, hanem lehetőséget teremt arra is, hogy vizsgáljuk a modellek robusztusságát, általánosítási képességét, valamint azt, hogyan reagálnak az adatok mennyiségi vagy minőségi változásaira. Ezért a képadatbázis nem csupán háttéranyag, hanem aktív és kulcsfontosságú szereplője a neurális hálózatokkal végzett kutatómunkának. [7] [7] [10] [10] [3]

2.5. Irodalomkutatás

A diplomamunka elkészítése során elsősorban a képzés során elsajátított elméleti és gyakorlati ismeretekre támaszkodtam, különösen a *Bevezetés a gépi tanulásba*, a *Gépi tanulás alapjai Python-ban* és a *Deep Learning* kurzusokon tanultakra. Ezek az alapok biztosították a technológiai és módszertani keretet a munka megvalósításához.

A projekt előkészítési szakaszában emellett alapos irodalomkutatást végeztem: áttekintettem a felhasznált modelleket bemutató tudományos publikációkat, témába vágó összefoglaló (survey) tanulmányokat, valamint a képosztályozás és neurális hálózatok alkalmazási lehetőségeit vizsgáló szakirodalmat. E fejezet célja ezen források rövid ismertetése, valamint a kutatási háttér bemutatása.

A felhasznált irodalmak részletes jegyzéke a dolgozat végén, illetve a projekt GitHub könyvtárában is elérhető.

2.5.1. A metrikák

Az osztályozási eredmények értékelésére szolgáló metrikák kiválasztásában és pontos értelmezésében jelentős segítséget nyújtott az *"Image Classification with Convolutional Neural Networks"* [3] című tanulmány. A cikk világos áttekintést ad

az olyan kulcsfontosságú mutatókról, mint az *accuracy*, *precision*, *recall*, *F1-score*, illetve a *confusion matrix* szerepe a modellek teljesítményének objektív értékelésében.

2.5.2. Áttekintő írások

Az irodalomkutatást áttekintő művek keresésével és értelmezésével kezdtem.

- "A Survey of Convolutional Neural Networks: Analysis, Applications, and Prospects"[7]
- "Review of deep learning: concepts, CNN architectures, challenges, applications, future directions"[10]
- "Understanding Deep Convolutional Networks"[11]
- "Benchmarking Neural Network Training Algorithms"[12]

2.5.3. A modellek és adathalmazok cikkei

Természetesen nagyon nagy segítséget jelentettek a felhasznált modelleket és kategorizálásokat ismertető írások. Ezek az írások a következők:

- A ResNet50 modell ismertetése.[13]
- DenseNet121 modell ismertetése.[14]
- EfficientNet-B0 modell ismertetése.[15]
- ConvNeXt-Tiny modell ismertetése.[16]
- ViT-B/16 modell ismertetése.[17]
- Inception-v3 modell ismertetése.[18]
- NASNet modell ismertetése.[19]
- ImageNet1K osztályozás ismertetése.[8]
- Places365 osztályozás ismertetése.[9]

2.5.4. Optimalizációs módszerek

Amikor az új modellt terveztem több optimalizációs megoldásnak is utánanéztem. Az alábbiakban az ezekhez tartozó irodalmakat sorolom fel.

- GELU (Gaussian Error Linear Unit) aktivációs függvény[4]
- Layer Normalization[5]
- Dropout regulárizáció[6]
- Batch Normalization (BatchNorm)[20]
- Adaptive Average Pooling (AdaptiveAvgPool2d)[21]

2.5.5. Egyéb irodalom

A további cikkek és írások amiket áttekintettem a munka megkezdése előtt az alábbiak:

- "A Survey on Deep Transfer Learning and Beyond"[22]
- "Landscape photo classification mechanism for context-aware photography support system" [23]
- "Photo Content Classification Using Convolutional Neural Network" [2]
- "An Analysis Of Convolutional Neural Networks For Image Classification"[1]

3. fejezet

Saját képadatbázis építése

A mesterséges intelligencia alapú képosztályozás hatékony működésének alapfeltétele a megfelelő minőségű és kellően reprezentatív tanítóadatbázis. Jelen dolgozat egyik legfontosabb és legidőigényesebb eleme volt egy ilyen képadatbázis összeállítása, amely nemcsak mennyiségében, hanem tartalmában és szerkezetében is jól illeszkedik a konvolúciós neurális hálózatok igényeihez. Mivel rendelkezésemre állt egy saját fotóarchívum, amely két évtizednyi, gondosan rendszerezett és archivált felvételt tartalmaz, adódott a lehetőség, hogy egyéni képtáramból építsek fel egy teljes értékű osztályozási adatbázist.

A kiindulási anyag döntő többsége NEF (Nikon Electronic Format) típusú RAW formátumban volt elérhető, amely minden színcsatorna és világossági komponens részletes információit tartalmazza. Ez a formátum ideális alapot nyújt a professzionális feldolgozáshoz, ugyanakkor szükségessé tette egy egyedi konverziós pipeline megtervezését és megvalósítását. A cél az volt, hogy a képek átalakítása során a lehető legkevesebb információ vesszen el, ugyanakkor teljesüljön minden olyan követelmény, amely a neurális hálózatok betanításához szükséges: fix képméret, egységes képarány, szabványos formátum, egyértelmű osztályozás, ismétlődésmentes elrendezés és metaadatok megőrzése.

A teljes fotóarchívum mérete meghaladta a 2 terabájtot, így a képek feldolgozása szakaszosan, 10 GB-os csomagokban történt, a saját gépem SSD tárhelyének igénybevételével. Ez nemcsak a feldolgozási sebességet növelte, hanem csökkentette az archiváló háttértárolók elhasználódásának kockázatát is. A képfeldolgozó pipeline automatikusan hajtotta végre a következő lépéseket: a NEF fájlok EXIF metaadatait megtartó konverzióját JPEG formátumba (80-as tömörítéssel), méretezést 224 kép-

pont szélességre, középre vágást 1:1 képarány eléréséhez, MD5-alapú fájlnev-képzést az ismétlődések kiszűrésére, valamint osztályozási és szűrési lépéseket. A kezdeti automatikus osztályozást többszörös kézi ellenőrzés és újraosztályozás követte, így fokozatosan alakult ki az adatbázis végleges struktúrája.

A kategóriák számát és tartalmát az osztályok kiegyensúlyozottságának elve, valamint a képanyag tartalmi homogenitása alapján határoztam meg. Az alacsony elemszámú osztályokat átcsoportosítottam, a túl nagy kategóriákat finomabb alkategóriákra bontottam, az irreleváns vagy túl heterogén osztályokat pedig elhagytam. A végső adatbázis több mint 180 000 képet tartalmaz, gondosan strukturált mappaszerkezetben, amely a tanító, validációs és tesztadatok 80-10-10 százalékos megosztását is tartalmazza.

A képadatbázis építése közben számos saját fejlesztésű segédprogram készült, amelyek automatizálták és nyomon követhetővé tették az egyes lépéseket. Ezek a programok nemcsak a képfeldolgozásért, hanem a statisztikai elemzésekért, vizualizációkért és a kategóriaeloszlás értékeléséért is felelősek. A fejezet hátralévő részében részletesen bemutatom az egyes lépéseket, a megvalósított pipeline-t, a feldolgozási logikát, valamint az e szakaszban keletkezett eredményeket és tapasztalatokat.

3.1. A forrásképek

A képadatbázis építése közben számos saját fejlesztésű segédprogram készült, amelyek automatizálták és nyomon követhetővé tették az egyes lépéseket. Ezek a programok nemcsak a képfeldolgozásért, hanem a statisztikai elemzésekért, vizualizációkért és a kategóriaeloszlás értékeléséért is felelősek. A fejezet hátralévő részében részletesen bemutatom az egyes lépéseket, a megvalósított pipeline-t, a feldolgozási logikát, valamint az e szakaszban keletkezett eredményeket és tapasztalatokat.

3.1.1. Motiváció

A képadatbázis építése közben számos saját fejlesztésű segédprogram készült, amelyek automatizálták és nyomon követhetővé tették az egyes lépéseket. Ezek a programok nemcsak a képfeldolgozásért, hanem a statisztikai elemzésekért, vizualizációkért és a kategóriaeloszlás értékeléséért is felelősek. A fejezet hátralévő részében részlete-

sen bemutatom az egyes lépéseket, a megvalósított pipeline-t, a feldolgozási logikát, valamint az e szakaszban keletkezett eredményeket és tapasztalatokat.

3.1.2. Források

A képadatbázis építése közben számos saját fejlesztésű segédprogram készült, amelyek automatizálták és nyomon követhetővé tették az egyes lépéseket. Ezek a programok nemcsak a képfeldolgozásért, hanem a statisztikai elemzésekért, vizualizációkért és a kategóriaeloszlás értékeléséért is felelősek. A fejezet hátralévő részében részletesen bemutatom az egyes lépéseket, a megvalósított pipeline-t, a feldolgozási logikát, valamint az e szakaszban keletkezett eredményeket és tapasztalatokat.

3.2. Forrás adathalmaz elemzése

3.2.1. Darabszámok

3.2.2. Méretek

3.2.3. Kategóriák

3.3. Adatbázis szerkezete

3.3.1. Képméret, formátum

3.3.2. Oszályozás

3.3.3. Kategóriák

3.3.4. Mappaszerkezet

3.4. Előfeldolgozás

3.4.1. Kötegelt adatgyűjtés

3.4.2. Méret és teljesítmény korlátok

3.5. Saját feldolgozó futószalag

3.5.1. Tulajdonságok

3.5.2. Szkript futószalag

Konvertálás

Méretezés

Vágás

Átnevezés

Ismétlődés szűrése

Kategorizálás

Csomagolás, véglegesítés

3.5.3. Performancia

4. fejezet

Modellek és metrikák kiválasztása

4.1. Metodika

4.2. Kiválasztott modellek

4.2.1. ResNet50

4.2.2. DenseNet121

4.2.3. EfficientNet-B0

4.2.4. ConvNeXt-Tiny

4.2.5. ViT-B/16

4.2.6. Inception-v3

4.2.7. NASNet

4.3. A kiválasztott metrikák:

4.3.1. Top-1 pontosság

4.3.2. Top-5 pontosság

4.3.3. Precision

4.3.4. Recall

4.3.5. F1-score

4.3.6. Train és Val loss

4.3.7. Train és Val pontosság

4.4. Összegzés

5. fejezet

Vizsgálati metodika

5.1. I. Fázis: Tanítás nélküli tesztelés

5.2. II. Fázis: Teljes tanítás

5.3. III. Fázis: Iteratív tanítás

5.4. IV. Fázis: Saját modell fejlesztése

6. fejezet

Szoftveres környezet

6.1. Lokális vagy Online

6.2. Google Colab lehetőségek

6.3. Tárolási problémák

6.4. Tanító és tesztelő programok

6.4.1. Tesztelés

6.4.2. Tanítás

6.4.3. Mérés

6.4.4. Problémák és megoldások

Sablon notebook-ok

LaTeX táblázatok

Confusion mátrixok

NASNet optimalizáció

6.5. Összefoglalás

7. fejezet

I. Fázis: Tanítás nélküli tesztelés

7.1. ResNet50

7.2. DenseNet121

7.3. EfficientNet-B0

7.4. ConvNeXt-Tiny

7.5. ViT-B/16

7.6. Inception-v3

7.7. NASNet

7.8. Összefoglaló

8. fejezet

II. Fázis: Teljes tanítás

8.1. ResNet50

8.2. DenseNet121

8.3. EfficientNet-B0

8.4. ConvNeXt-Tiny

8.5. ViT-B/16

8.6. Inception-v3

8.7. NASNet

8.8. Összefoglaló

9. fejezet

III. Fázis: Iteratív tanítás

9.1. ResNet50

9.2. DenseNet121

9.3. EfficientNet-B0

9.4. ConvNeXt-Tiny

9.5. ViT-B/16

9.6. Inception-v3

9.7. NASNet

9.8. Összefoglaló

10. fejezet

IV. Fázis: Saját modell fejlesztése

10.1. A ResNet18

10.2. A Base fej

10.3. A Deep fej

10.4. A Hybrid-v1 fej

10.5. A Hybrid-v2 fej

10.6. Mérések

10.6.1. I. Fázis: Tanítás nélküli tesztelés

10.6.2. II. Fázis: Teljes tanítás

10.6.3. III. Fázis: Iteratív tanítás

10.7. Összefoglalás

11. fejezet

Legfontosabb eredmények

12. fejezet

Összefoglaló

A dolgozat célja a fotó osztályozási probléma vizsgálata volt neurális hálózatokkal saját nagyméretű címkézett adatbázison. A vizsgálat során összegyűjtöttem 180750 egyedi fotót az elmúlt 20 év saját készítésű képeiből, ebből címkézett adatbázist készítettem SBphotothemes180k néven kétféle címkézéssel. Az ImageNet1K címkékből 114 kategória adta az első osztályozást a 300 képnél kisebb osztályok megszüntetése után, a Places365 címkékből 121 kategória adta a második osztályozást. Ezek után 80-10-10 arányban felosztottam tanító, validáló és tesztelő adathalmazra az adatbázist. Az adathalmaz képeit 224*244 méretű négyzetes jpg 80 tömörítésű képekké konvertáltam. Így a közel 2TB mennyiségű forrásképből nagyjából 10GB méretű adatbázis készült. Az elkészült adatbázison vizsgáltam az osztályozási eloszlásokat, és az EXIF adatokat. Az osztályozások estén az átlagos osztályméret 1500 kép körül alakult, a medián 1000 kép körül alakult ami jó, de mivel természetes adatokról beszélünk, így az aszimmetria magas, 8.4 és a szórás is magas 3200 körüli tehát tipikus Long-tail eloszlást mutat. Az EXIF adatok konverzió közbeni megőrzése és elemzése különösen fontos volt a részletes statisztikák elvégzéséhez és a későbbi vizsgálatok lehetőségeinek biztosításához. Az így elkészített adatbázis segítségével három fázisos vizsgálatot végeztem hét ismert és gyakran használt modellen. Ezek a modellek a ResNet50, DenseNet121, EfficientNet-B0, ConvNeXt-Tiny, ViT-B/16, Inception-v3, NASNet voltak. Az alkalmazott metrikák a következők lettek: Top-1 és Top-5 pontosság, Precision, Recall, F1-score. Ezeken túl vizsgáltam a tanítás közbeni validációs és tanítási pontosságokat. Mindhárom vizsgálatot ugyanazon az adathalmazon végeztem, de más-más tanítóhalmazzal tanítottam. A három vizsgálati fázis a tanítás nélküli tesztelés, majd a teljes tanítás utáni vizsgálat volt, végül az iteratívan

növekvő tanítóhalmaz vizsgálata következett. A vizsgálat első lépése a tanítás nélküli modellek tesztelése volt a beépített súlyokkal. Ekkor a modellek 50% körüli Top 1 és 80% körüli Top 5 pontosságot és 40% körüli Precision-t nyújtottak. Itt a ConvNeXt-Tiny és ViT-B/16 emelkedtek ki. A második fázis során a teljes 144000 képes tanítóhalmazon tanítottam minden modellt 10 epoch-on keresztül. Ekkor a modellek 75% körüli Top 1 és 90% körüli Top 5 pontosságot és 70% körüli Precision-t nyújtottak a EfficientNet-B0 és NASNet emelkedtek ki. Az utolsó vizsgálat során mindig a tanítatlan modelltől indulva 1000, 5000, 10000, 25000 képes tanítóhalmazon vizsgáltam a modelleket szintén 10 epoch-on keresztül. Az adataink alapján a ConvNeXt-Tiny és az EfficientNet-B0 modellek kiemelkedtek 25000 mintaszámmal történő tanítás után, míg a ResNet50 és DenseNet121 modellek gyengébben teljesítettek az alacsonyabb mintaszámokon, de növekvő mintaszámmal jelentős javulást mutattak. Eközben az Inception-v3 és a ViT-B/16 pedig a kis adathalmazon mutatott pontosság terén emelkedtek ki. Ezután megkíséreltem elkészíteni egy kis méretű, lokális alkalmazásra optimalizált erőforrástakarékos modellt a ResNet18-ra építve egy saját fejrész kifejlesztésével. Ennek során 4 modellt készítettem, egy egyrétegű, egy mély, és két modern fejrésszel rendelkezőt. Ezen a négy modellen is elvégeztem a fent ismertetett három mérési fázist. Az egyrétegű fej meglepően jól teljesített, a mély fejrész viszont jelentősen alulmaradt a fenti metrikákban, a modern fejrész csak kicsit nyújtott nagyobb pontosságot, mint az egyrétegű, de jelentősen gyorsabban futott. Összességében a kifejlesztett modell csak kis mértékben maradt alul a vizsgált hatalmas modellektől, de futási teljesítménye sokkal jobb azokénál így nem pontosságkritikus, de erőforráskímélő megoldásokhoz, például hordozható eszközök számára ideális. Összességében a nagyméretű adathalmaz, a többféle osztályozás, a nagy mennyiségű mért adat és a saját modellek további vizsgálatok alapját képezhetik a jövőben.

13. fejezet

További lehetőségek

14. fejezet

Befejezés

Irodalomjegyzék

- [1] Neha Sharma, Vibhor Jain és Anju Mishra. „An Analysis Of Convolutional Neural Networks For Image Classification”. *Procedia Computer Science* 132 (2018. jan.), 377–384. old. DOI: 10.1016/j.procs.2018.05.198.
- [2] Yilin Hou. „Photo Content Classification Using Convolutional Neural Network”. *Journal of Physics: Conference Series* 1651.1 (2020. nov.), 12179. old. DOI: 10.1088/1742-6596/1651/1/012179. URL: <https://dx.doi.org/10.1088/1742-6596/1651/1/012179>.
- [3] Alfonso Ramos Michel és tsai. *Image Classification with Convolutional Neural Networks*. 2021. júl., 445–473. old. ISBN: 978-3-030-70541-1. DOI: 10.1007/978-3-030-70542-8_18.
- [4] Dan Hendrycks és Kevin Gimpel. „Gaussian Error Linear Units (GELUs)”. *arXiv preprint arXiv:1606.08415* (2016).
- [5] Jimmy Lei Ba, Jamie Ryan Kiros és Geoffrey E Hinton. „Layer Normalization”. *arXiv preprint arXiv:1607.06450* (2016).
- [6] Nitish Srivastava és tsai. „Dropout: A Simple Way to Prevent Neural Networks from Overfitting”. *Journal of Machine Learning Research*. 15. köt. 2014, 1929–1958. old.
- [7] Zewen Li és tsai. „A Survey of Convolutional Neural Networks: Analysis, Applications, and Prospects”. *arXiv preprint arXiv:2004.02806* (2020).
- [8] Jia Deng és tsai. „ImageNet: A Large-Scale Hierarchical Image Database”. *2009 IEEE Conference on Computer Vision and Pattern Recognition*. IEEE. 2009, 248–255. old.
- [9] Bolei Zhou és tsai. „Places: A 10 million Image Database for Scene Recognition”. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. 2017, 1452–1460. old.

- [10] Laith Alzubaidi és tsai. „Review of deep learning: concepts, CNN architectures, challenges, applications, future directions”. *Journal of Big Data* 8.1 (2021), 53. old.
- [11] Stéphane Mallat. „Understanding Deep Convolutional Networks”. *arXiv preprint arXiv:1601.04920* (2016).
- [12] MLCommons Algorithms Working Group. *Benchmarking Neural Network Training Algorithms*. <https://arxiv.org/html/2306.07179>. 2023.
- [13] Kaiming He és tsai. „Deep Residual Learning for Image Recognition”. *arXiv preprint arXiv:1512.03385* (2015).
- [14] Gao Huang és tsai. „Densely Connected Convolutional Networks”. *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2017, 4700–4708. old.
- [15] Mingxing Tan és Quoc V Le. „EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks”. *International Conference on Machine Learning*. PMLR. 2019, 6105–6114. old.
- [16] Zhuang Liu és tsai. „A ConvNet for the 2020s”. *arXiv preprint arXiv:2201.03545* (2022).
- [17] Alexey Dosovitskiy és tsai. „An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale”. *arXiv preprint arXiv:2010.11929* (2020).
- [18] Christian Szegedy és tsai. „Rethinking the Inception Architecture for Computer Vision”. *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2016, 2818–2826. old.
- [19] Barret Zoph és tsai. „Learning Transferable Architectures for Scalable Image Recognition”. *arXiv preprint arXiv:1707.07012* (2017).
- [20] Sergey Ioffe és Christian Szegedy. „Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift”. *Proceedings of the 32nd International Conference on Machine Learning*. 2015, 448–456. old.
- [21] Kaiming He és tsai. „Spatial Pyramid Pooling in Deep Convolutional Networks for Visual Recognition”. *European Conference on Computer Vision*. 2014, 346–361. old.

- [22] Y. Zhang, S. Wang és Y. Liu. „A Survey on Deep Transfer Learning and Beyond”. *Mathematics* 10.19 (2022), 3619. old.
- [23] Nuttapoom Amornpashara és tsai. „Landscape photo classification mechanism for context-aware photography support system”. *2015 IEEE International Conference on Consumer Electronics (ICCE)*. 2015, 663–666. old. DOI: 10.1109/ICCE.2015.7066570.

Ábrák jegyzéke

Táblázatok jegyzéke

Forráskódjegyzék